

DIPARTIMENTO DI INGEGNERIA INFORMATICA, MODELLISTICA,
ELETTRONICA E SISTEMISTICA

Corso di Laurea Magistrale in Ingegneria Informatica

Progetto Modelli Statistici e Statistical Learning

Statisticool

Davide Cinelli 269491, Giuseppe Cuiuri 269480, Agazio Geracitano 269290, Vittorio Iusi 269170, Antonio Pio Francica 269017, Giuseppe Scaramuzzo 263955, Rocco Vardaro 264097

ANNO ACCADEMICO 2024-2025

Indice

Indice **1**

1 Introduzione **3**

1.1 Descrizione del Dataset 3

1.2 Descrizione del Dataset 3

1.3 Obiettivo 4

2 Preprocessing **5**

3 Analisi descrittive **7**

4 Modello Lineare **10**

4.1 Analisi Collinearità 12

4.2 Calcolo di misure per individuare la multicollinearità 13

4.3 Best Subset Selection e Backward Selection 16

4.3.1 Best Subset Selection 17

4.3.2 Backward Selection 17

5 Analisi Eteroschedasticità **19**

5.1 Modello log-lin 22

5.2 Modello log-lin pesato 24

5.3 Modello pesato sulle ordinate stimate del modello lineare 26

5.4 Modello pesato sulle ordinate stimate del modello log lin 28

5.5 Test sui regressori quantitativi 30

5.6 Approccio con interazioni tra variabili nel modello lineare 34

5.6.1 Selezione automatica dei regressori usando AIC 34

5.7 Modello di interazione pesato 37

6 Regolarizzazione **39**

6.1 Ridge Regression 39

6.2 Lasso 41

6.3 Elastic Net 42

6.3.1 Elastic Net $\alpha = 0.25$ 42

6.3.2 Elastic Net $\alpha = 0.5$ 43

6.3.3 Elastic Net $\alpha = 0.75$ 43

6.4 Confronto tra modello con interazioni WLS, Elastic Net(0.5) e log-lin 44

6.5 Confronto dei residui 45

6.6 Confronto finale tra i modelli 46

7 Conclusioni **48**

Capitolo 1

Introduzione

1.1 Descrizione del Dataset

Questo dataset raccoglie i dettagli di come le emissioni di CO_2 di un veicolo possano variare in relazione a diverse caratteristiche. I dati sono stati estratti dal sito ufficiale di open data del governo canadese e coprono un periodo di 7 anni. Il dataset contiene **7385 righe e 12 colonne**. Di seguito una descrizione generale dei dati, inclusi gli acronimi utilizzati e il loro significato.

Caratteristiche principali del dataset

1.2 Descrizione del Dataset

Ogni riga rappresenta un veicolo, mentre le colonne descrivono le sue caratteristiche e le emissioni di CO2. Di seguito, un riepilogo delle colonne:

- **Make e Model**: Marca e modello del veicolo.
- **Vehicle Class**: Classe del veicolo (es. compatto, SUV).
- **Engine Size (L)**: Dimensioni del motore in litri.
- **Cylinders**: Numero di cilindri del motore.
- **Transmission**: Tipo di trasmissione (es. automatica, manuale).
- **Fuel Type**: Tipo di carburante utilizzato (es. benzina, diesel).

- **Fuel Consumption City (L/100 km)**: Consumo di carburante in città.
- **Fuel Consumption Hwy (L/100 km)**: Consumo di carburante in autostrada.
- **Fuel Consumption Comb (L/100 km)**: Consumo di carburante combinato.
- **Fuel Consumption Comb (mpg)**: Consumo di carburante combinato in miglia per gallone.
- **CO2 Emissions (g/km)**: Emissioni di CO2 espresse in grammi per chilometro.

Tutte le colonne sono complete, senza valori mancanti, e i dati sono suddivisi in attributi categorici (es. *Make*, *Vehicle Class*) e numerici (es. *Engine Size*, *CO2 Emissions*). Questo dataset è utile per analizzare il rapporto tra le caratteristiche dei veicoli e le loro emissioni ambientali.

1.3 Obiettivo

L'obiettivo principale di questo studio è identificare i fattori determinanti che influenzano la variabile dipendente CO_2 **Emissions(g/km)**, utilizzando come regressori le caratteristiche tecniche e prestazionali dei veicoli. In particolare, si analizzano le relazioni tra le emissioni di CO2 e variabili come la *dimensione del motore*, il *numero di cilindri*, il *tipo di trasmissione*, il *tipo di carburante* e i *consumi di carburante* (in città, autostrada e combinati).
Attraverso questa analisi, si mira a costruire un modello statistico che permetta di quantificare il contributo di ciascun fattore alle emissioni di CO2, fornendo indicazioni utili per interventi volti a ridurre l'impatto ambientale dei veicoli.

Capitolo 2

Preprocessing

Il preprocessing dei dati è stato realizzato seguendo una serie di passaggi chiave per ottimizzare il dataset e renderlo più pulito al fine di garantire una corretta scelta del modello.
Di seguito vengono descritti i principali step:

- **Eliminazione di colonne a basso contenuto informativo**: Le colonne `Make`, `Model`, `Vehicle Class`, `Transmission`, `Fuel.Consumption.Comb (mpg)` sono state rimosse dal dataset poiché non forniscono informazioni utili per la stima delle emissioni di CO_2 (le prime quattro) o sono ridondanti (l'ultima poichè cambia solo l'unità di misura rispetto a `Fuel.Consumption.Comb (L/100 km)`).

- **Riduzione delle categorie per la variabile** `Fuel Type`: La variabile `Fuel Type` presentava molteplici categorie. Sono state individuate le due categorie più frequenti e le rimanenti sono state raggruppate sotto una nuova etichetta denominata `Other`. Successivamente, sono state generate due variabili dummy per rappresentare le due categorie principali, mentre la categoria `Other` è stata esclusa per evitare problemi di perfetta multicollinearità (trappola delle dummy).

- **Riposizionamento della variabile target**: La variabile dipendente `CO2 Emissions (g/km)` è stata spostata in ultima posizione nel dataset per semplificare la creazione dei modelli statistici.

- **Suddivisione del dataset in training e test set**: Il dataset è stato suddiviso in due insiemi: un *training set* contenente il 70% delle osservazioni, utilizzato per costruire il modello, e un *test set* con il restante 30%, utilizzato per valutarne le prestazioni. La suddivisione è stata effettuata in maniera casuale, garantendo la riproducibilità attraverso l'impostazione di un seed fisso.

Capitolo 3

Analisi descrittive

Analisi di Correlazione

Si genera un grafico per ogni variabile indipendente in cui vengono mostrate tutte le eventuali relazioni di correlazione con la variabile dipendente. Questi sono utili anche per identificare eventuali pattern di relazioni non lineari (polinomiali, logaritmiche, ecc.).

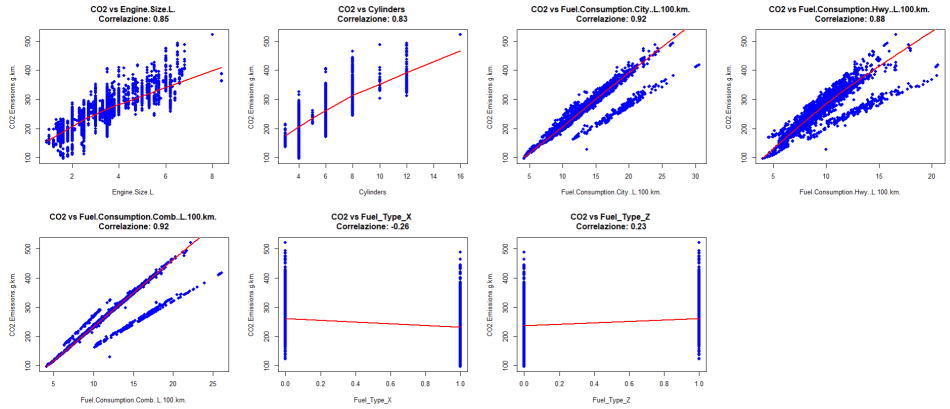


Figura 3.1: Analisi di correlazione

Nonostante l'elevata correlazione, si nota che per le due variabili `Engine Size (L)` e `Cylinders` potrebbero esserci relazioni quadratiche o logaritmiche.

Matrice di Correlazione

La matrice di correlazione 3.2 rappresenta i coefficienti di correlazione tra tutte le variabili numeriche del dataset. È uno strumento essenziale per analizzare

la relazione tra variabili e per individuare eventuali correlazioni tra coppie di regressori.

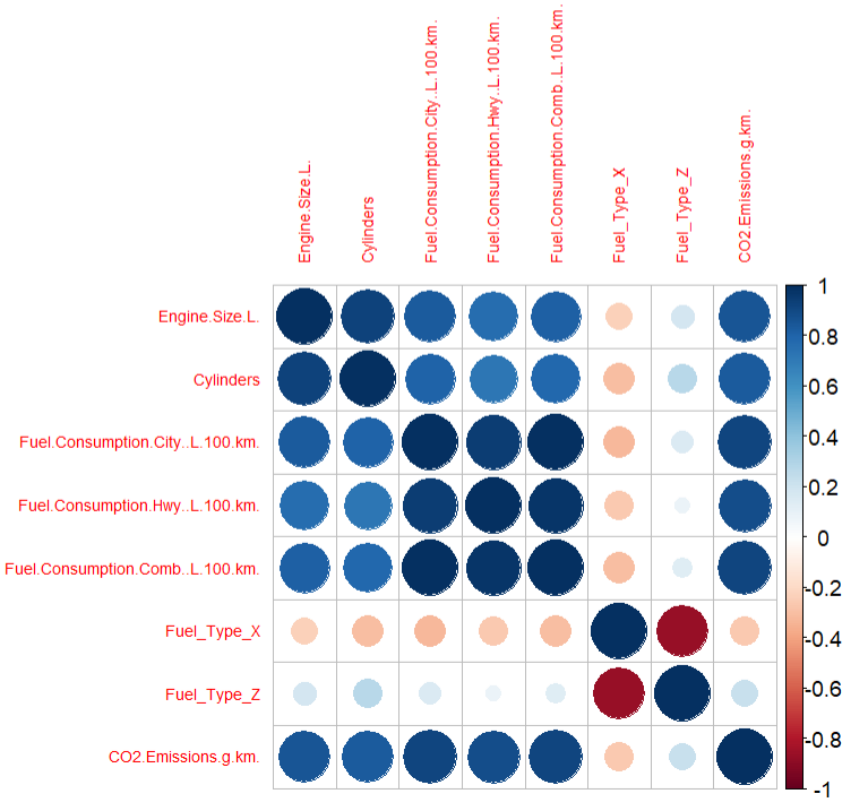


Figura 3.2: Matrice di correlazione

Dettagli del Grafico

L'analisi della matrice è stata effetuando seguendo il seguente pattern:

- Cerchi di grandi dimensioni e colore intenso indicano una forte correlazione.
- Cerchi piccoli o assenti indicano una correlazione debole o nulla.

La matrice di correlazione riportata in Figura 3.2 mostra le relazioni lineari tra le variabili incluse nel *training set*. I principali risultati osservati sono:

- **Forte correlazione positiva tra consumo di carburante ed emissioni di CO_2**: Le variabili relative al consumo di carburante (`Fuel Consumption City (L/100 km)`, `Fuel Consumption Hwy (L/100 km)`, `Fuel Consumption Comb (L/100 km)`) mostrano una forte correlazione

positiva con le emissioni di CO_2 (`CO2 Emissions (g/km)`), evidenziando che un maggiore consumo è associato a un aumento delle emissioni.

- **Correlazione positiva tra consumo combinato in L per 100 km e emissioni di CO_2**: La variabile `Fuel Consumption Comb (L per 100 km)` presenta una forte correlazione positiva con le emissioni di CO2, come previsto, poiché valori più alti in *L per 100 km* indicano una minore efficienza del carburante e quindi maggiori emissioni.

- **Moderata correlazione positiva tra dimensione del motore e cilindri con le emissioni di CO_2**: Le variabili `Engine Size (L)` e `Cylinders` mostrano una moderata correlazione positiva con le emissioni di CO2, suggerendo che motori più grandi o con più cilindri tendono a produrre più emissioni.

- **Forte correlazione tra i consumi di carburante**: Le variabili `(Fuel Consumption City (L/100 km)`, `Fuel Consumption Hwy (L/100 km)` e `Fuel Consumption Comb (L/100 km)` sono fortemente correlate, poichè forniscono indicativamente le stesse informazioni, anche se in circostanze diverse (città e autostrada).

Capitolo 4

Modello Lineare

Come punto di partenza per la nostra analisi, abbiamo stimato un modello pieno che include tutti i regressori disponibili nel dataset. Questo approccio consiste nel costruire un modello di regressione lineare in cui ogni variabile indipendente viene utilizzata come predittore della variabile dipendente. L'obiettivo è valutare l'importanza di ciascun predittore e comprendere come ciascuno di essi contribuisca a spiegare la variabilità della variabile target. Questo modello funge da base di confronto, permettendo di identificare eventuali regressori non significativi o ridondanti, e fornisce una panoramica iniziale delle relazioni tra le variabili.

```
Call:
lm(formula = CO2.Emissions.g.km. ~ ., data = train)

Residuals:
    Min      1Q  Median      3Q     Max
-82.461  -6.601  -0.695   5.499 111.035

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                     -13.6162     1.7726  -7.682 1.87e-14 ***
Engine.Size.L.                    3.3175     0.5160   6.429 1.40e-10 ***
Cylinders                         4.1036     0.3666  11.194  < 2e-16 ***
Fuel.Consumption.City..L.100.km.  0.5650     3.0077   0.188  0.85101
Fuel.Consumption.Hwy..L.100.km.   0.7906     2.4793   0.319  0.74983
Fuel.Consumption.Comb..L.100.km. 15.4532     5.4517   2.835  0.00461 **
Fuel_Type_X                      49.5896     1.0484  47.300  < 2e-16 ***
Fuel_Type_Z                      51.5043     1.0366  49.686  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 16.8 on 5161 degrees of freedom
Multiple R-squared:  0.9186,    Adjusted R-squared:  0.9185
F-statistic:  8323 on 7 and 5161 DF,  p-value: < 2.2e-16
```

Figura 4.1: Modello lineare

Risultati principali

- **Coefficiente di determinazione**: Il valore di R^2 è pari a 0.9186, indicando che circa il 92% della variabilità nelle emissioni di CO2 è spiegata dai regressori inclusi nel modello. L'R^2 corretto è anch'esso elevato (0.9185), suggerendo che il modello è robusto e ben adattato ai dati.

- **Significatività dei regressori**:

  - Le variabili `Engine Size (L)`, `Cylinders`, e `Fuel Consumption Comb (mpg)` risultano altamente significative (p-value < 0.001).

  - Le variabili dummy `Fuel Type X` e `Fuel Type Z` sono anch'esse significative (p-value < 0.001), suggerendo che il tipo di carburante influisce sulle emissioni di CO2.

  - Le variabili `Fuel Consumption City (L/100 km)` e `Fuel Consumption Hwy (L/100 km)` non risultano significative (p-value > 0.05), probabilmente a causa di multicollinearità con `Fuel Consumption Comb (L/100 km)`.

Interpretazione dei coefficienti

- Il coefficiente di `Engine Size (L)` (*dimensione del motore*) è pari a 3.3175, indicando che un aumento di un litro nella cilindrata del motore è associato a un incremento medio di circa 3.02 g/km di CO2.

- Il coefficiente di `Fuel Consumption Comb (L/100 km)` è pari a 15.4532, suggerendo che un aumento del consumo del carburante (L/100 km) è associato a un aumento delle emissioni di CO2.

- Le variabili `Fuel Type X` e `Fuel Type Z` presentano coefficienti simili (circa 50), indicando che i veicoli con questi tipi di carburante producono mediamente emissioni di CO2 più elevate rispetto alla categoria di riferimento.

Dati i risultati dell'analisi di correlazione (possibili relazioni quadratiche o logaritmiche), si tenta di inserire queste trasformazioni come regressori nel modello lineare.

```
Call:
lm(formula = CO2.Emissions.g.km. ~ . + I(Engine.Size.L.^2) +
    I(Cylinders^2) + I(log(Engine.Size.L.)) + I(log(Cylinders)),
    data = train)

Residuals:
    Min      1Q  Median      3Q     Max
-83.456  -6.489  -0.607   5.469 109.489

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                      39.8791    11.3531   3.513 0.000448 ***
Engine.Size.L.                  -68.6217     7.9395  -8.643  < 2e-16 ***
Cylinders                        23.0913     7.9734   2.896 0.003795 **
Fuel.Consumption.City..L.100.km.  0.3411     2.9628   0.115 0.908342
Fuel.Consumption.Hwy..L.100.km.   1.0189     2.4418   0.417 0.676498
Fuel.Consumption.Comb..L.100.km. 15.4638     5.3692   2.880 0.003992 **
Fuel_Type_X                      50.0018     1.0353  48.297  < 2e-16 ***
Fuel_Type_Z                      50.5377     1.0294  49.097  < 2e-16 ***
I(Engine.Size.L.^2)               4.5437     0.5504   8.255  < 2e-16 ***
I(Cylinders^2)                   -0.6405     0.2757  -2.323 0.020215 *
I(log(Engine.Size.L.))          120.2168    11.8083  10.181  < 2e-16 ***
I(log(Cylinders))               -54.2400    25.3795  -2.137 0.032632 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 16.54 on 5157 degrees of freedom
Multiple R-squared:  0.9212,    Adjusted R-squared:  0.921
F-statistic:  5481 on 11 and 5157 DF,  p-value: < 2.2e-16
```

Figura 4.2: Modello lineare con regressori non lineari

Si nota che l'R^2 è pari a 0.9212, cioè migliora di 0.0026. Aggiungere dei regressori complica il modello, quindi visto il quasi insignificante miglioramento si sceglie di mantenere il modello lineare puro (**principio di parsimonia**).

4.1 Analisi Collinearità

Si procede ad analizzare il determinante della matrice $\mathbf{X}'\mathbf{X}$, che rappresenta un indicatore preliminare per valutare la collinearità o multicollinearità tra i regressori.

```
> det
[1] 2.128978e+31
```

Figura 4.3: Determinante

La collinearità o multicollinearità tende a far avvicinare a zero il determinante. Nel nostro caso, come evidenziato dalla figura, il determinante è molto maggiore di zero, indicando che i regressori non presentano una forte collinearità.

Tuttavia, il determinante non è un indicatore completamente affidabile per valutare la multicollinearità, in quanto può essere influenzato dalla scala e dall'unità di misura dei dati.

Condition Number

Per ottenere una misura più robusta, si procede al calcolo del condition number, basato sul rapporto tra il massimo e il minimo autovalore della matrice $\mathbf{X^tX}$. Questo fornisce un'indicazione più affidabile della presenza di multicollinearità tra i regressori. Valori elevati di di questa metrica suggeriscono presenza di multicollinearità, dato che valori elevati potrebbero essere dovuti a valori molto piccoli del minimo (che si ricorda, è la causa di un determinate prossimo allo zero). In generale si ritiene che valori maggiori o uguali a 30 segnalano rischio di multicollinearità. Notiamo che il nostro valore è pari a 7393.531.

```
> autoval <- eigen(mat)
> eigenvalues <- abs(autoval$values)
> condition.number <- sqrt(max(eigenvalues)/min(eigenvalues))
> condition.number
[1] 7393.531
```

Figura 4.4: Condition number

4.2 Calcolo di misure per individuare la multicollinearità

Si procede con il calcolo di tre indicatori: VIF (Variance Inflation Factor), Tolerance e Indice di Determinazione, utili per identificare i regressori responsabili di questo fenomeno.

```
> # Calcolo di misure per individuare multicollinearità
> (vif(model))                        #VIF
                  Engine.Size.L.                        Cylinders Fuel.Consumption.City..L.100.km.
                        9.042121                         8.254327                       2049.456233
 Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.                       Fuel_Type_X
                       560.860542                      4594.935202                          5.030949
                     Fuel_Type_Z
                         4.844643
> (toll<-1/vif(model))                #Tolleranza
                  Engine.Size.L.                        Cylinders Fuel.Consumption.City..L.100.km.
                      0.1105935155                    0.1211485850                     0.0004879343
 Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.                       Fuel_Type_X
                      0.0017829744                    0.0002176309                     0.1987696408
                     Fuel_Type_Z
                      0.2064135528
> ((vif(model)-1)/vif(model))       #Indice di determinazione
                  Engine.Size.L.                        Cylinders Fuel.Consumption.City..L.100.km.
                       0.8894065                        0.8788514                        0.9995121
 Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.                       Fuel_Type_X
                       0.9982170                        0.9997824                        0.8012304
                     Fuel_Type_Z
                       0.7935864
```

Figura 4.5: Vif, Tollerance e Indice di determinazione del modello 1

Il VIF misura l'influenza della multicollinearità su un dato regressore. Valori elevati di VIF indicano un'elevata correlazione lineare tra un regressore e gli altri regressori inclusi nel modello.

- **Fuel Consumption City (L/100 km)** presenta un valore di VIF estremamente elevato (4594.94), indicando una fortissima multicollinearità con le altre variabili relative al consumo di carburante (`Fuel Consumption City (L/100 km)`, `Fuel Consumption Hwy (L/100 km)`, ecc.).

- Anche `Fuel Consumption City (L/100 km)` e `Fuel Consumption Hwy (L/100 km)` mostrano valori di VIF molto elevati (rispettivamente 2049.45 e 560.86), confermando la ridondanza tra queste variabili.

Generalmente, un valore di VIF superiore a 10 è considerato problematico, mentre valori molto più elevati (come quelli osservati per il consumo di carburante) richiedono interventi specifici. Volendo seguire un approccio meccanicco si dovrebbe eliminare il regressore `Fuel Consumption Comb (L/100 km)`, ma si nota che questo fornisce più informazioni degli altri due, quindi si sceglie di eliminare il regressore `Fuel Consumption City (L/100 km)` e si ripropone il summary del modello.

```
Call:
lm(formula = CO2.Emissions.g.km. ~ . - Fuel.Consumption.City..L.100.km.,
    data = train)

Residuals:
    Min      1Q  Median      3Q     Max
-82.478  -6.603  -0.733   5.491 111.018

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                     -13.6178     1.7724  -7.683 1.84e-14 ***
Engine.Size.L.                    3.3186     0.5159   6.432 1.37e-10 ***
Cylinders                         4.1046     0.3665  11.199  < 2e-16 ***
Fuel.Consumption.Hwy..L.100.km.   0.3361     0.5401   0.622    0.534
Fuel.Consumption.Comb..L.100.km. 16.4733     0.4763  34.586  < 2e-16 ***
Fuel_Type_X                      49.5882     1.0483  47.304  < 2e-16 ***
Fuel_Type_Z                      51.5058     1.0365  49.693  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 16.8 on 5162 degrees of freedom
Multiple R-squared:  0.9186,    Adjusted R-squared:  0.9185
F-statistic:  9712 on 6 and 5162 DF,  p-value: < 2.2e-16
```

Figura 4.6: Modello 2

```
>
> (vif(model2))
                  Engine.Size.L.                        Cylinders  Fuel.Consumption.Hwy..L.100.km.
                        9.040952                         8.252616                        26.616481
Fuel.Consumption.Comb..L.100.km.                       Fuel_Type_X                      Fuel_Type_Z
                       35.079977                         5.030704                         4.844376
> (toll<-1/vif(model2))
                  Engine.Size.L.                        Cylinders  Fuel.Consumption.Hwy..L.100.km.
                      0.11060783                       0.12117370                       0.03757071
Fuel.Consumption.Comb..L.100.km.                       Fuel_Type_X                      Fuel_Type_Z
                      0.02850629                       0.19877933                       0.20642493
> ((vif(model2)-1)/vif(model2))
                  Engine.Size.L.                        Cylinders  Fuel.Consumption.Hwy..L.100.km.
                       0.8893922                        0.8788263                        0.9624293
Fuel.Consumption.Comb..L.100.km.                       Fuel_Type_X                      Fuel_Type_Z
                       0.9714937                        0.8012207                        0.7935751
>
```

Figura 4.7: Vif, Tollerance e Indice di determinazione del modello 2

Notiamo che il VIF del `Fuel Consumption Hwy (L/100 km)` supera la soglia (anche in questo caso non si sceglie volutamente `Fuel Consumption Comp (L/100 km)`), procediamo come prima andandolo ad eliminare.

```
Call:
lm(formula = CO2.Emissions.g.km. ~ . - Fuel.Consumption.City..L.100.km. -
    Fuel.Consumption.Hwy..L.100.km., data = train)

Residuals:
    Min      1Q  Median      3Q     Max
-82.505  -6.651  -0.776   5.471 111.179

Coefficients:
                                 Estimate Std. Error t value Pr(>|t|)
(Intercept)                     -13.4060     1.7393  -7.708 1.53e-14 ***
Engine.Size.L.                    3.3005     0.5151   6.408 1.61e-10 ***
Cylinders                         4.0688     0.3619  11.242  < 2e-16 ***
Fuel.Consumption.Comb..L.100.km. 16.7529     0.1581 105.941  < 2e-16 ***
Fuel_Type_X                      49.6313     1.0459  47.452  < 2e-16 ***
Fuel_Type_Z                      51.4958     1.0363  49.692  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 16.8 on 5163 degrees of freedom
Multiple R-squared:  0.9186,    Adjusted R-squared:  0.9185
F-statistic: 1.166e+04 on 5 and 5163 DF,  p-value: < 2.2e-16
```

Figura 4.8: Modello 3

```
>
> (vif(model3))
                Engine.Size.L.                      Cylinders Fuel.Consumption.Comb..L.100.km.
                      9.012144                       8.049477                         3.867247
                   Fuel_Type_X                    Fuel_Type_Z
                      5.008714                       4.843204
> (toll<-1/vif(model3))
                Engine.Size.L.                      Cylinders Fuel.Consumption.Comb..L.100.km.
                      0.1109614                      0.1242317                        0.2585819
                   Fuel_Type_X                    Fuel_Type_Z
                      0.1996520                      0.2064749
> ((vif(model3)-1)/vif(model3))
                Engine.Size.L.                      Cylinders Fuel.Consumption.Comb..L.100.km.
                      0.8890386                      0.8757683                        0.7414181
                   Fuel_Type_X                    Fuel_Type_Z
                      0.8003480                      0.7935251
>
```

Figura 4.9: Vif, Tollerance e Indice di Determinazione del modello 3

I risultati mostrano che la multicollinearità è gestibile, con VIF generalmente sotto il valore critico di 10 e tolleranze sufficientemente alte.

4.3 Best Subset Selection e Backward Selection

La *Best Subset Selection* e la *Backward Selection* sono due tecniche utilizzate per la selezione automatica dei regressori. Sebbene abbiano lo stesso obiettivo, ovvero identificare il sottoinsieme ottimale di variabili indipendenti, differiscono nel loro approccio.

4.3.1 Best Subset Selection

La *Best Subset Selection* esplora tutte le possibili combinazioni di regressori per identificare il modello ottimale. Questo metodo analizza ogni possibile sottoinsieme di variabili e valuta i modelli risultanti secondo un criterio (ad esempio, R^2, AIC o BIC).

Vantaggi: Fornisce il miglior modello possibile in termini di ottimalità globale.

Svantaggi: È computazionalmente costosa, specialmente quando il numero di variabili è elevato, poiché il numero di combinazioni cresce esponenzialmente.

	NumPredictors	R2	AdjR2	AIC	BIC
1	1	0.8452296	0.8451996	32485.29	32498.39
2	2	0.8768578	0.8768101	31305.64	31325.29
3	3	0.9068027	0.9067485	29867.45	29893.65
4	4	0.9179684	0.9179048	29209.81	29242.57
5	5	0.9186156	0.9185367	29170.87	29210.17
6	6	0.9186217	0.9185271	29172.48	29218.34
7	7	0.9186222	0.9185118	29174.45	29226.85

Figura 4.10: Best Subset Selection

Si sceglie il modello con 5 predittori, poichè è quello che massimizza l'indice di determinazione corretto e minimizza AIC e BIC.

```
> # Visualizza i regressori selezionati per il modello con 5 predittori
> print(selected_predictors)
[1] "Engine.Size.L."                "Cylinders"                     "Fuel.Consumption.Comb..L.100.km."
[4] "Fuel_Type_X"                   "Fuel_Type_Z"
```

Figura 4.11: Regressori

4.3.2 Backward Selection

La *Backward Selection*, invece, parte dal modello pieno che include tutte le variabili indipendenti. Successivamente, rimuove iterativamente la variabile meno significativa fino a ottenere un modello ottimale.

Vantaggi: È più veloce e meno costosa dal punto di vista computazionale rispetto alla *Best Subset Selection*.

Svantaggi: Può non trovare il miglior modello globale, poiché si basa su un approccio *greedy* che valuta localmente la significatività delle variabili.

```
Call:
lm(formula = CO2.Emissions.g.km. ~ Engine.Size.L. + Cylinders +
    Fuel.Consumption.Comb..L.100.km. + Fuel_Type_X + Fuel_Type_Z,
    data = data)

Residuals:
    Min      1Q  Median      3Q     Max
-83.018  -6.748  -0.666   5.513 110.538

Coefficients:
                                 Estimate Std. Error t value Pr(>|t|)
(Intercept)                      -11.5943     1.4274  -8.123 5.30e-16 ***
Engine.Size.L.                     3.4774     0.4272   8.139 4.63e-16 ***
Cylinders                          4.0751     0.2984  13.655  < 2e-16 ***
Fuel.Consumption.Comb..L.100.km.  16.6131     0.1299 127.921  < 2e-16 ***
Fuel_Type_X                       48.7821     0.8578  56.870  < 2e-16 ***
Fuel_Type_Z                       50.6334     0.8521  59.419  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 16.65 on 7379 degrees of freedom
Multiple R-squared:  0.9191,    Adjusted R-squared:  0.919
F-statistic: 1.676e+04 on 5 and 7379 DF,  p-value: < 2.2e-16
```

Figura 4.12: Bckward model

Nella nostra analisi abbiamo usato entrambe le tecniche e dai risultati abbiamo ottentuto che il miglior modello si ottiene utilizzando 5 regressori tar cui troviamo:

- Engine.Size.L
- Cylinders
- Fuel.Consuption.Comb..L.100.Km.
- Fuel Type X
- Fuel Type Z

Questi risultati confermano le analisi effetuate in precedenza manualmente.

Capitolo 5

Analisi Eteroschedasticità

L'eteroschedasticità si verifica quando la varianza degli errori o residui in un modello di regressione cambia al variare dei valori delle variabili indipendenti o dei valori predetti. In altre parole, gli errori non hanno una dispersione uniforme, ma tendono ad aumentare o diminuire in modo sistematico. Questo fenomeno viola una delle principali assunzioni della regressione lineare, che richiede che gli errori abbiano una varianza costante (omoschedasticità). Quando è presente l'eteroschedasticità, i coefficienti stimati dal modello rimangono corretti, ma le loro misure di affidabilità, come gli intervalli di confidenza e i test di significatività, potrebbero risultare sbagliate. Di conseguenza, le conclusioni (come le previsioni su nuove unità statistiche) tratte dal modello potrebbero essere poco affidabili. Per riconoscere l'eteroschedasticità, si analizza la distribuzione dei residui rispetto ai valori predetti: se si osserva un pattern, come una forma a "ventaglio" o un aumento della dispersione, è probabile che ci sia eteroschedasticità. Per risolvere il problema, si possono utilizzare trasformazioni dei dati, metodi di regressione robusta o modelli che pesano gli errori in modo opportuno.

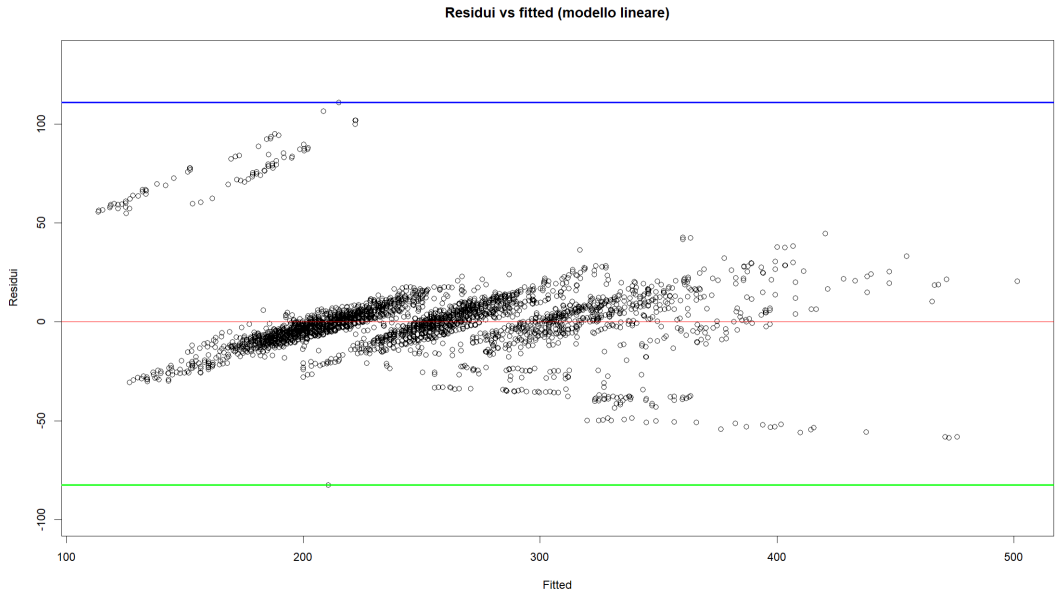


Figura 5.1: Analisi dei residui del modello con tutti i regressori

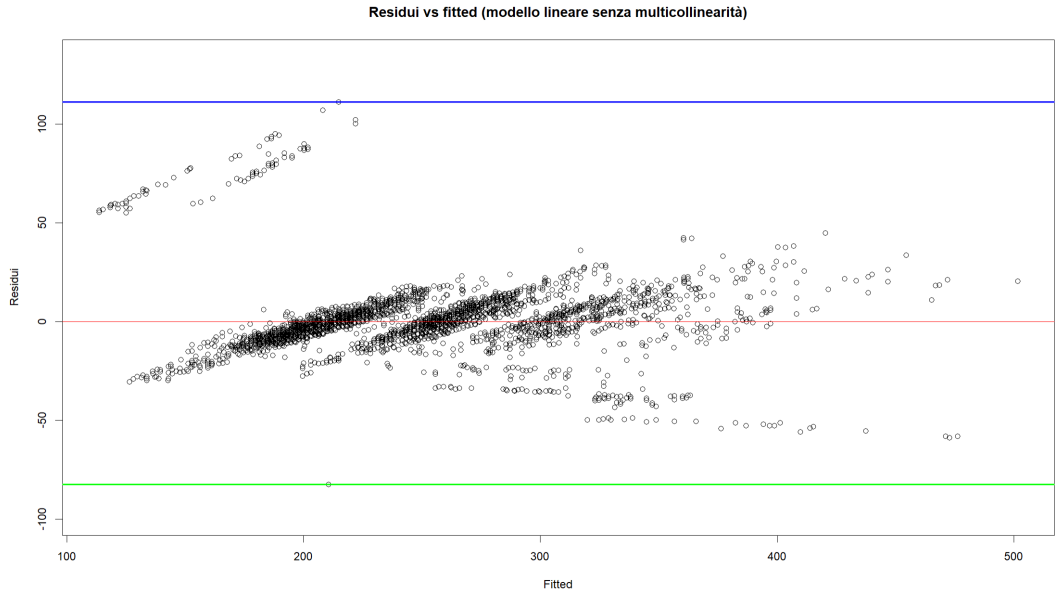


Figura 5.2: Analisi dei residui del modello senza Multicollinearità

L'analisi ha evidenziato che i residui non seguono un andamento casuale, bensì mostrano una struttura evidente, caratterizzata da una distribuzione a "fasci diagonali". Un'altra criticità rilevata riguarda la varianza non costante dei residui (eteroschedasticità). La dispersione dei residui aumenta al crescere dei valori predetti, violando l'assunzione di omoschedasticità richiesta nei modelli di regressione lineare. Sono stati inoltre individuati alcuni outlier, ovvero punti che si discostano significativamente dal gruppo principale dei residui.

Per avere conferma analitica della presenza di omoschedasticità, vengono effettuati i test di Breusch-Pagan e di White. I test analizzano se la varianza dei residui è costante o se, al contrario, dipende dai valori predetti o da altre variabili.

```
> # Test di breusch-pagan
> bptest(model3)

        studentized Breusch-Pagan test

data:  model3
BP = 2792.2, df = 5, p-value < 2.2e-16
```

Figura 5.3: Test di breusch-pagan

```
> # Test di white
> fit_mod_2<- y_fit^2
> modwhite<- lm(residui^2~y_fit+fit_mod_2)
> summary(modwhite)

Call:
lm(formula = residui^2 ~ y_fit + fit_mod_2)

Residuals:
    Min      1Q  Median      3Q     Max
-3064.7  -324.3   -87.1    -9.5 12086.7

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  5.175e+03  2.094e+02   24.71   <2e-16 ***
y_fit       -3.738e+01  1.592e+00  -23.48   <2e-16 ***
fit_mod_2    6.782e-02  2.941e-03   23.06   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 949.4 on 5166 degrees of freedom
Multiple R-squared:  0.09665,   Adjusted R-squared:  0.0963
F-statistic: 276.3 on 2 and 5166 DF,  p-value: < 2.2e-16
```

Figura 5.4: Test di white

Nel nostro caso, il valore del p-value ottenuto è inferiore a 0.05, il che implica che si rigetta l'ipotesi nulla (H_0), suggerendo la presenza di eteroschedasticità nel modello. In altre parole, la varianza dei residui non è costante, il che potrebbe indicare che il modello non cattura completamente la relazione tra le variabili.

5.1 Modello log-lin

Un modello log-lin è una regressione in cui la variabile dipendente viene trasformata con il logaritmo naturale, mentre le variabili indipendenti restano lineari. È usato per modellare relazioni esponenziali o analizzare variazioni percentuali nella variabile dipendente.

```
Call:
lm(formula = log(CO2.Emissions.g.km.) ~ . - Fuel.Consumption.City..L.100.km. -
    Fuel.Consumption.Hwy..L.100.km., data = train)

Residuals:
     Min       1Q   Median       3Q      Max
-0.50326 -0.02534  0.00841  0.03336  0.41173

Coefficients:
                                 Estimate Std. Error t value Pr(>|t|)
(Intercept)                     4.4624293  0.0083339 535.456  < 2e-16 ***
Engine.Size.L.                  0.0161352  0.0024680   6.538 6.85e-11 ***
Cylinders                       0.0057993  0.0017342   3.344 0.000832 ***
Fuel.Consumption.Comb..L.100.km. 0.0697824  0.0007577  92.098  < 2e-16 ***
Fuel_Type_X                     0.1882845  0.0050115  37.570  < 2e-16 ***
Fuel_Type_Z                     0.2106217  0.0049654  42.418  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.08048 on 5163 degrees of freedom
Multiple R-squared:  0.8843,    Adjusted R-squared:  0.8842
F-statistic:  7890 on 5 and 5163 DF,  p-value: < 2.2e-16
```

Figura 5.5: Modello della trasformazione log lin

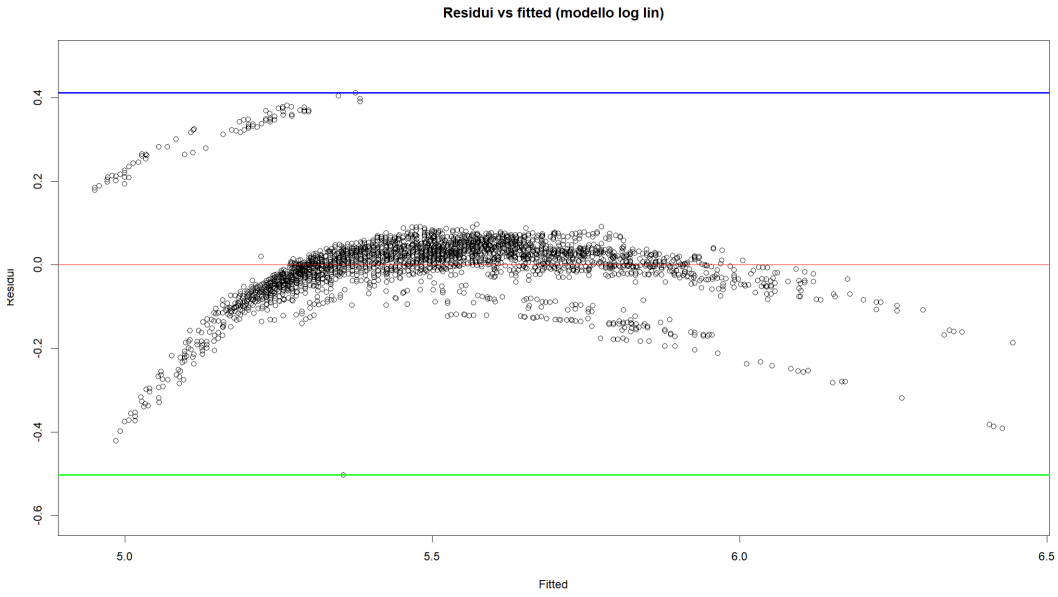


Figura 5.6: Analisi dei residui del modello log lin

Il grafico dei residui mostra un chiaro pattern curvilineo, indicando che il modello log-lin non cattura pienamente la relazione tra le variabili. Inoltre, si

osserva eteroschedasticità, con una variazione non costante dei residui lungo i valori predetti, e la presenza di alcuni outlier che potrebbero influenzare i risultati. Questo suggerisce la necessità di migliorare la specificazione del modello, considerando trasformazioni aggiuntive, l'inclusione di altre variabili o l'adozione di tecniche robuste per gestire l'eteroschedasticità e gli outlier.

```
> # Test di breusch-pagan
> bptest(model_log)

        studentized Breusch-Pagan test

data:  model_log
BP = 2214.6, df = 5, p-value < 2.2e-16
```

Figura 5.7: Test di breusch-pagan

```
> # Test di white
> fit_mod_2<- y_fit^2
> modwhite<- lm(residui^2~y_fit+fit_mod_2)
> summary(modwhite)

Call:
lm(formula = residui^2 ~ y_fit + fit_mod_2)

Residuals:
      Min        1Q    Median        3Q       Max
-0.056228 -0.007997 -0.000691  0.002713  0.246136

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.317372   0.107424   40.19   <2e-16 ***
y_fit       -1.537725   0.038659  -39.78   <2e-16 ***
fit_mod_2    0.136849   0.003475   39.38   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.0178 on 5166 degrees of freedom
Multiple R-squared:  0.2534,    Adjusted R-squared:  0.2531
F-statistic: 876.6 on 2 and 5166 DF,  p-value: < 2.2e-16
```

Figura 5.8: Test di White

Ancora una volta analizzando i risultati del test si deve rigettare l'ipotesi nulla.

5.2 Modello log-lin pesato

Si pesa il modello secondo la tecnica WLS (Weighted Least Squares), una generalizzazione della tecnica dei minimi quadrati. Si ponderano quindi i residui e si verifica il modello.

```
Call:
lm(formula = log(CO2.Emissions.g.km.) ~ . - Fuel.Consumption.City..L.100.km. -
    Fuel.Consumption.Hwy..L.100.km., data = train, weights = weight)

Weighted Residuals:
    Min      1Q  Median      3Q     Max
-1.7521 -0.9987  0.9979  0.9997  1.5021

Coefficients:
                                 Estimate Std. Error t value Pr(>|t|)
(Intercept)                     4.384e+00  6.585e-03  665.73   <2e-16 ***
Engine.Size.L.                  1.608e-02  3.821e-05  420.89   <2e-16 ***
Cylinders                       5.782e-03  1.050e-05  550.88   <2e-16 ***
Fuel.Consumption.Comb..L.100.km. 6.982e-02  2.301e-05 3034.71   <2e-16 ***
Fuel_Type_X                     2.670e-01  6.582e-03   40.56   <2e-16 ***
Fuel_Type_Z                     2.893e-01  6.581e-03   43.96   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.9859 on 5163 degrees of freedom
Multiple R-squared:      1,     Adjusted R-squared:      1
F-statistic: 4.866e+08 on 5 and 5163 DF,  p-value: < 2.2e-16
```

Figura 5.9: Modello WLS della trasformazione log-lin

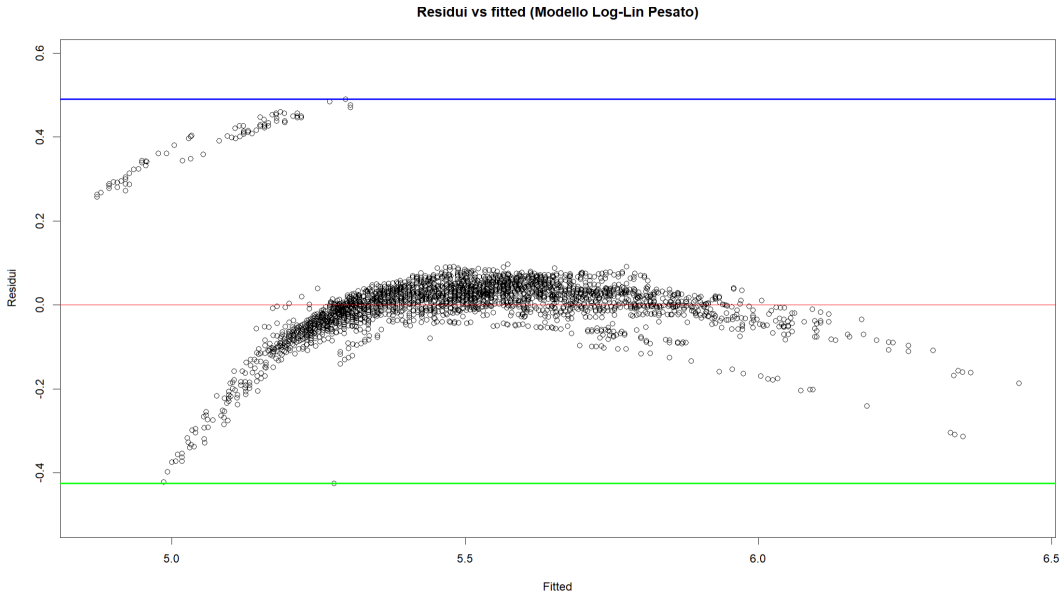


Figura 5.10: Analisi dei residui del modello log-lin pesato

Il grafico mostra la relazione tra i valori predetti (*Fitted*) e i residui del modello log-lin pesato. Si nota una chiara struttura nei residui, evidenziata da un andamento curvilineo che indica una possibile violazione delle ipotesi di

indipendenza e casualità dei residui. Inoltre, la varianza dei residui non appare costante, suggerendo la presenza di eteroschedasticità. Questo suggerisce che il modello potrebbe necessitare di ulteriori miglioramenti per soddisfare le assunzioni della regressione.

```
> # Test di Breusch-Pagan
> bptest(model_log_wls)

        studentized Breusch-Pagan test

data:  model_log_wls
BP = 4.5826e+10, df = 5, p-value < 2.2e-16

>
> # Test di White
> fit_mod_2_wls <- y_fit_wls^2
> modwhite_wls <- lm(residui_wls^2 ~ y_fit_wls + fit_mod_2_wls)
> summary(modwhite_wls)

Call:
lm(formula = residui_wls^2 ~ y_fit_wls + fit_mod_2_wls)

Residuals:
      Min        1Q    Median        3Q       Max
-0.064797 -0.009843  0.000361  0.005498  0.225005

Coefficients:
               Estimate Std. Error t value Pr(>|t|)
(Intercept)    5.331848   0.131980   40.40   <2e-16 ***
y_fit_wls     -1.889040   0.047633  -39.66   <2e-16 ***
fit_mod_2_wls  0.167143   0.004294   38.92   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02245 on 5166 degrees of freedom
Multiple R-squared:  0.2949,    Adjusted R-squared:  0.2946
F-statistic:  1080 on 2 and 5166 DF,  p-value: < 2.2e-16
```

Figura 5.11: Test di Breusch-Pagan e di White

Analizzando i risultati del test si deve rigettare l'ipotesi nulla.

5.3 Modello pesato sulle ordinate stimate del modello lineare

```
Call:
lm(formula = CO2.Emissions.g.km. ~ . - Fuel.Consumption.City..L.100.km. -
    Fuel.Consumption.Hwy..L.100.km., data = train_fitted)

Residuals:
     Min       1Q   Median       3Q      Max
-0.54313 -0.01927  0.00663  0.03045  0.36860

Coefficients:
                                 Estimate Std. Error t value Pr(>|t|)
(Intercept)                       -1.4980     0.1195 -12.533   <2e-16 ***
Engine.Size.L.                     8.4737     0.8817   9.611   <2e-16 ***
Cylinders                         10.0524     0.4932  20.383   <2e-16 ***
Fuel.Consumption.Comb..L.100.km.  41.7085     1.9111  21.825   <2e-16 ***
Fuel_Type_X                       88.4621     5.3600  16.504   <2e-16 ***
Fuel_Type_Z                       95.1898     5.7462  16.566   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.07353 on 5163 degrees of freedom
Multiple R-squared:  0.2358,    Adjusted R-squared:  0.2351
F-statistic: 318.7 on 5 and 5163 DF,  p-value: < 2.2e-16
```

Figura 5.12: Modello pesato sulle ordinate stimate del modello lineare

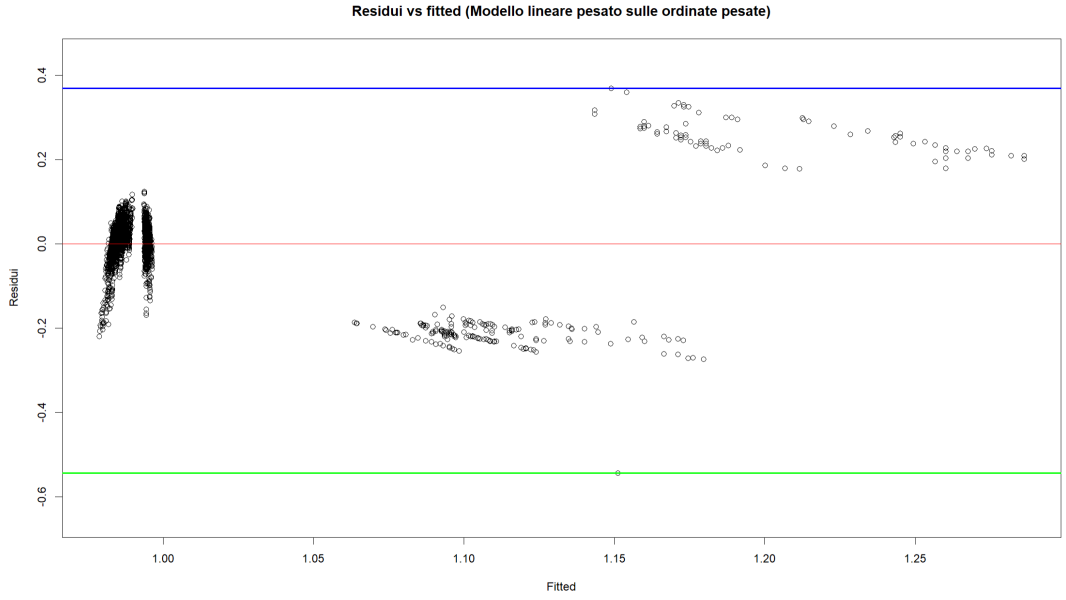


Figura 5.13: Residui vs fitted (Modello lineare pesato sulle ordinate pesate)

I dati mostrano una varianza non costante, indicando possibili problemi di eteroschedasticità. Inoltre, si osservano gruppi distinti che potrebbero riflettere una struttura intrinseca non catturata dal modello.

```
> # Test di breusch-pagan
> bptest(model_fit)

        studentized Breusch-Pagan test

data:  model_fit
BP = 3968.9, df = 5, p-value < 2.2e-16

>
> # Test di white
> fit_mod_2<- y_fit^2
> modwhite<- lm(residui^2~y_fit+fit_mod_2)
> summary(modwhite)

Call:
lm(formula = residui^2 ~ y_fit + fit_mod_2)

Residuals:
      Min        1Q    Median        3Q       Max
-0.033855 -0.003754 -0.000175  0.001771  0.237284

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.48255    0.04213  -35.19   <2e-16 ***
y_fit        2.49137    0.07830   31.82   <2e-16 ***
fit_mod_2   -1.00192    0.03615  -27.72   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.007155 on 5166 degrees of freedom
Multiple R-squared:  0.7793,    Adjusted R-squared:  0.7792
F-statistic:  9119 on 2 and 5166 DF,  p-value: < 2.2e-16
```

Figura 5.14: Test di breusch-pagan e di White

5.4 Modello pesato sulle ordinate stimate del modello log lin

```
Call:
lm(formula = CO2.Emissions.g.km. ~ . - Fuel.Consumption.City..L.100.km. -
    Fuel.Consumption.Hwy..L.100.km., data = train_fitted)

Residuals:
    Min      1Q  Median      3Q     Max
-16.435  -1.168  -0.058   1.077  19.645

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                      -1.5095     0.3893  -3.878 0.000107 ***
Engine.Size.L.                    3.4380     0.5329   6.452 1.21e-10 ***
Cylinders                         4.1156     0.3786  10.870  < 2e-16 ***
Fuel.Consumption.Comb..L.100.km. 16.7300     0.1805  92.704  < 2e-16 ***
Fuel_Type_X                      43.4671     1.0979  39.590  < 2e-16 ***
Fuel_Type_Z                      45.6919     1.0877  42.010  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.086 on 5163 degrees of freedom
Multiple R-squared:  0.8778,    Adjusted R-squared:  0.8777
F-statistic:  7421 on 5 and 5163 DF,  p-value: < 2.2e-16
```

Figura 5.15: Modello pesato sulle ordinate stimate del modello log lin

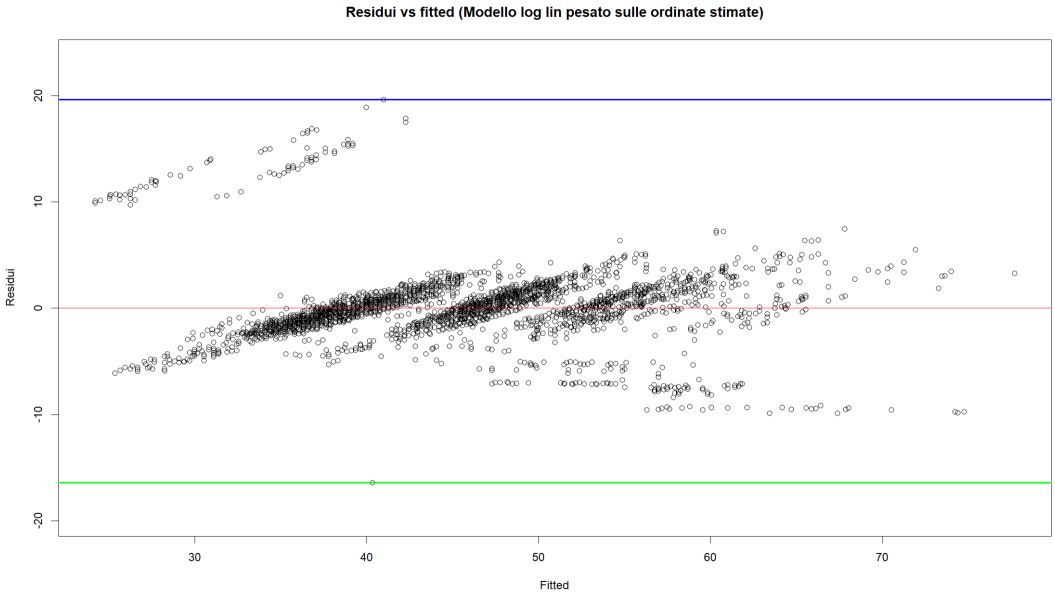


Figura 5.16: Residui vs fitted (Modello log lin pesato sulle ordinate stimate)

Il modello log-lin pesato non mostra miglioramenti rispetto ai precedenti. La presenza di outlier e un pattern residuo suggeriscono che potrebbero esserci ulteriori margini di ottimizzazione nel modello.

```
> # Test di breusch-pagan
> bptest(model_fit)

        studentized Breusch-Pagan test

data:  model_fit
BP = 3172, df = 5, p-value < 2.2e-16

>
> # Test di white
> fit_mod_2<- y_fit^2
> modwhite<- lm(residui^2~y_fit+fit_mod_2)
> summary(modwhite)

Call:
lm(formula = residui^2 ~ y_fit + fit_mod_2)

Residuals:
   Min     1Q Median     3Q    Max
-81.21 -10.08  -4.32  -0.88 379.19

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 236.358170  10.265230   23.02   <2e-16 ***
y_fit        -9.783663   0.442301  -22.12   <2e-16 ***
fit_mod_2     0.102020   0.004674   21.83   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 30.56 on 5166 degrees of freedom
Multiple R-squared:  0.08676,   Adjusted R-squared:  0.08641
F-statistic: 245.4 on 2 and 5166 DF,  p-value: < 2.2e-16
```

Figura 5.17: Test di Breusch-Pagan e White

5.5 Test sui regressori quantitativi

Si vogliono verificare eventuali relazioni ("responsabilità") dei regressori con i residui, cioè se esistono regressori più responsabili di altri per la variabilità non costante dei residui. La verifica viene effettuata per i regressori quantitativi (non si tengono in considerazione le variabili dummy nè i regressori fuori dal modello log lin, per ora considerato il migliore).

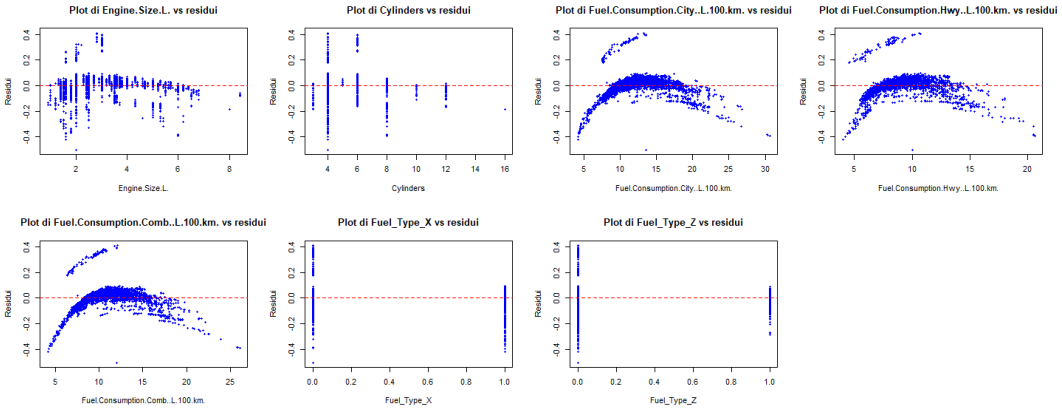


Figura 5.18: Correlazione tra ogni regressore e i residui

Si effettua anche il test di Breusch-Pagan per ogni regressore.

```
> #Engine.Size.L.
> bptest(model_log, ~Engine.Size.L. , data = train)

        studentized Breusch-Pagan test

data:  model_log
BP = 8.9668, df = 1, p-value = 0.002749

> #Cylinders
> bptest(model_log, ~Cylinders , data = train)

        studentized Breusch-Pagan test

data:  model_log
BP = 9.9264, df = 1, p-value = 0.001629

> #Fuel.Consumption.City..L.100.km. (fuori modello)
> bptest(model_log, ~Fuel.Consumption.City..L.100.km. , data = train)

        studentized Breusch-Pagan test

data:  model_log
BP = 9.6535, df = 1, p-value = 0.00189

> #Fuel.Consumption.Hwy..L.100.km. (fuori modello)
> bptest(model_log, ~Fuel.Consumption.Hwy..L.100.km. , data = train)

        studentized Breusch-Pagan test

data:  model_log
BP = 0.013773, df = 1, p-value = 0.9066

> #Fuel.Consumption.Comb..L.100.km.
> bptest(model_log, ~Fuel.Consumption.Comb..L.100.km. , data = train)

        studentized Breusch-Pagan test

data:  model_log
BP = 4.0324, df = 1, p-value = 0.04463
```

Figura 5.19: Test di Breush-Pagan sui regressori

Si nota che il regressore quantitativo presente nel modello con il valore di BP più alto è `Fuel.Consumption.Comb..L.100.km.`

```
> #Fuel_Type_X (categorica)
> bptest(model_log, ~Fuel_Type_X , data = train)

        studentized Breusch-Pagan test

data:  model_log
BP = 34.683, df = 1, p-value = 3.88e-09

> #Fuel_Type_Z (categorica)
> bptest(model_log, ~Fuel_Type_Z , data = train)

        studentized Breusch-Pagan test

data:  model_log
BP = 256.07, df = 1, p-value < 2.2e-16
```

Figura 5.20: Test di Breush-Pagan sui regressori

```
Call:
lm(formula = CO2.Emissions.g.km. ~ . - Fuel.Consumption.City..L.100.km. -
    Fuel.Consumption.Hwy..L.100.km., data = train_fitted)

Residuals:
    Min      1Q  Median      3Q     Max
-9.8257 -0.2735  0.1532  0.5073  6.3868

Coefficients: (1 not defined because of singularities)
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                      19.2108     0.1158 165.845   <2e-16 ***
Engine.Size.L.                    1.1126     0.4524   2.459    0.014 *
Cylinders                         3.2885     0.3407   9.653   <2e-16 ***
Fuel.Consumption.Comb..L.100.km.      NA         NA      NA       NA
Fuel_Type_X                      18.8028     0.6495  28.949   <2e-16 ***
Fuel_Type_Z                      21.2915     0.7685  27.707   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.444 on 5164 degrees of freedom
Multiple R-squared:  0.2419,    Adjusted R-squared:  0.2413
F-statistic: 411.9 on 4 and 5164 DF,  p-value: < 2.2e-16
```

Figura 5.21: Modello log lin pesato su un regressore

Si nota che il regressore su cui si pesa il modello diventa statisticamente non significativo, poichè diventa una colonna di tutti 1 (costante).

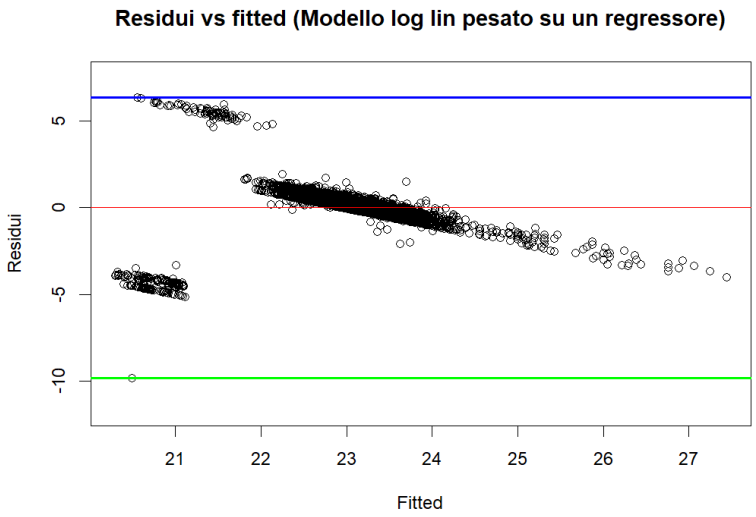


Figura 5.22: Residui vs fitted (Modello log lin pesato su un regressore

```
> # Test di breusch-pagan
> bptest(model_fit)

        studentized Breusch-Pagan test

data:  model_fit
BP = 2779.3, df = 4, p-value < 2.2e-16

>
> # Test di white
> fit_mod_2<- y_fit^2
> modwhite<- lm(residui^2~y_fit+fit_mod_2)
> summary(modwhite)

Call:
lm(formula = residui^2 ~ y_fit + fit_mod_2)

Residuals:
    Min      1Q  Median      3Q     Max
-14.754  -1.151  -0.040   0.832  70.785

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 1338.65072   15.36918   87.10   <2e-16 ***
y_fit       -112.23127    1.34229  -83.61   <2e-16 ***
fit_mod_2      2.35033    0.02932   80.15   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.381 on 5166 degrees of freedom
Multiple R-squared:  0.7187,    Adjusted R-squared:  0.7186
F-statistic:  6600 on 2 and 5166 DF,  p-value: < 2.2e-16
```

Figura 5.23: Test di Breush-Pagan e di White

Si nota che, anche applicando questa trasformazione, i residui non si stabilizzano. I test di Breusch-Pagan e di White lo certificano.

5.6 Approccio con interazioni tra variabili nel modello lineare

Visti gli scarsi risultati ottenuti finora nella riduzione dell'eteroschedasticità, si tenta una nuova trasformazione, realizzata tramite le interazioni tra i regressori già esistenti nel modello.

5.6.1 Selezione automatica dei regressori usando AIC

Per scegliere i regressori tra tutte le combinazioni delle interazioni, si fa uso di una tecnica di selezione automatica denominata stepAIC; questa, minimizzando la metrica AIC, esplora diverse combinazioni di variabili per identificare quelle che meglio contribuiscono al modello, tenendo conto sia della loro importanza che del rischio di eccessiva complessità.

```
Call:
lm(formula = CO2.Emissions.g.km. ~ Engine.Size.L. + Cylinders +
    Fuel.Consumption.City..L.100.km. + Fuel.Consumption.Hwy..L.100.km. +
    Fuel.Consumption.Comb..L.100.km. + Fuel_Type_X + Fuel_Type_Z +
    Fuel.Consumption.Hwy..L.100.km.:Fuel_Type_X + Fuel.Consumption.Hwy..L.100.km.:Fuel_Type_Z +
    Fuel.Consumption.City..L.100.km.:Fuel_Type_Z + Fuel.Consumption.City..L.100.km.:Fuel_Type_X +
    Fuel.Consumption.City..L.100.km.:Fuel.Consumption.Comb..L.100.km. +
    Cylinders:Fuel.Consumption.Hwy..L.100.km. + Engine.Size.L.:Fuel_Type_Z +
    Engine.Size.L.:Fuel_Type_X + Engine.Size.L.:Fuel.Consumption.Comb..L.100.km. +
    Engine.Size.L.:Cylinders + Cylinders:Fuel.Consumption.City..L.100.km.,
    data = train)

Residuals:
    Min      1Q  Median      3Q     Max
-91.488  -2.284   0.696   2.115  80.868

Coefficients:
                                                                 Estimate Std. Error t value Pr(>|t|)
(Intercept)                                                     147.83530    2.45116  60.312  < 2e-16 ***
Engine.Size.L.                                                   31.22648    1.29120  24.184  < 2e-16 ***
Cylinders                                                         5.38957    0.65460   8.233 2.28e-16 ***
Fuel.Consumption.City..L.100.km.                                -20.09083    1.37274 -14.636  < 2e-16 ***
Fuel.Consumption.Hwy..L.100.km.                                   9.21500    1.23129   7.484 8.43e-14 ***
Fuel.Consumption.Comb..L.100.km.                                 12.19026    2.27247   5.364 8.48e-08 ***
Fuel_Type_X                                                    -148.09109    1.61467 -91.716  < 2e-16 ***
Fuel_Type_Z                                                    -147.65172    1.66307 -88.783  < 2e-16 ***
Fuel.Consumption.Hwy..L.100.km.:Fuel_Type_X                      -4.20593    0.54295  -7.746 1.13e-14 ***
Fuel.Consumption.Hwy..L.100.km.:Fuel_Type_Z                      -4.18480    0.54013  -7.748 1.12e-14 ***
Fuel.Consumption.City..L.100.km.:Fuel_Type_Z                     22.93289    0.42832  53.542  < 2e-16 ***
Fuel.Consumption.City..L.100.km.:Fuel_Type_X                     23.04328    0.43103  53.461  < 2e-16 ***
Fuel.Consumption.City..L.100.km.:Fuel.Consumption.Comb..L.100.km.  0.46096    0.02238  20.602  < 2e-16 ***
Cylinders:Fuel.Consumption.Hwy..L.100.km.                        -0.26101    0.08535  -3.058  0.00224 **
Engine.Size.L.:Fuel_Type_Z                                      -28.72697    0.78182 -36.744  < 2e-16 ***
Engine.Size.L.:Fuel_Type_X                                      -28.81859    0.77608 -37.133  < 2e-16 ***
Engine.Size.L.:Fuel.Consumption.Comb..L.100.km.                  -0.98579    0.09250 -10.657  < 2e-16 ***
Engine.Size.L.:Cylinders                                          1.33868    0.12051  11.108  < 2e-16 ***
Cylinders:Fuel.Consumption.City..L.100.km.                       -0.54037    0.06917  -7.812 6.78e-15 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.953 on 5150 degrees of freedom
Multiple R-squared:  0.9861,    Adjusted R-squared:  0.986
F-statistic: 2.028e+04 on 18 and 5150 DF,  p-value: < 2.2e-16
```

Figura 5.24: Modello con interazioni

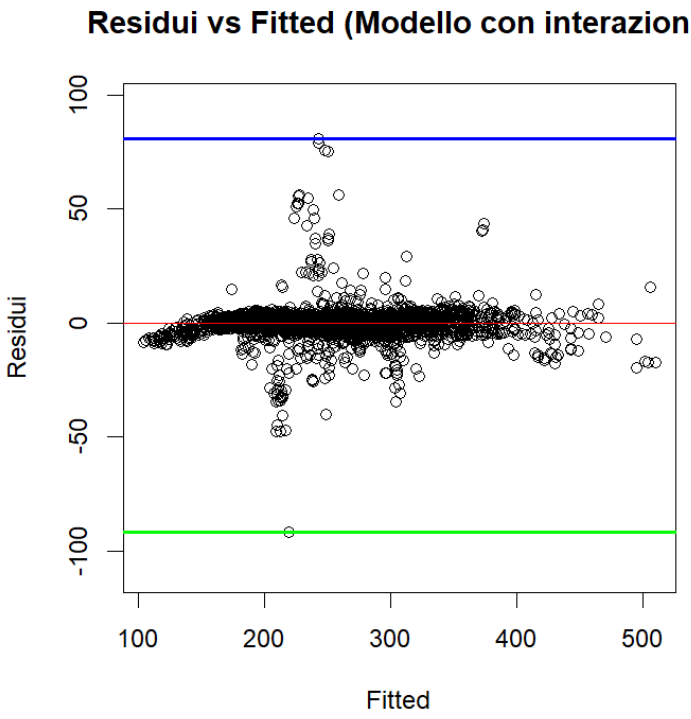


Figura 5.25: Modello con Interazione

Si può osservare dal grafico che i residui seguono una distribuzione uniforme, che suggerisce, in prima analisi, l'assenza di eteroschedasticità. Per confermare questa osservazione visiva, abbiamo effettuato i test di Breusch-Pagan e di White. Quest'ultimo conferma l'assenza di eteroschedastcità, mentre il primo rigetta ancora l'ipotesi nulla. Si tenta quindi di migliorare questo modello.

```
> # Test di breusch-pagan
> bptest(interaction_model)

        studentized Breusch-Pagan test

data:  interaction_model
BP = 1274.7, df = 18, p-value < 2.2e-16

>
> # Test di white
> fit_mod_inter<- y_fit^2
> modwhite<- lm(residui^2~y_fit+fit_mod_inter)
> summary(modwhite)

Call:
lm(formula = residui^2 ~ y_fit + fit_mod_inter)

Residuals:
   Min     1Q Median     3Q    Max
 -56.2  -48.1  -41.4  -34.1 8323.6

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)   -4.384e+01  6.004e+01  -0.730    0.465
y_fit          6.259e-01  4.546e-01   1.377    0.169
fit_mod_inter -9.792e-04  8.369e-04  -1.170    0.242

Residual standard error: 307.3 on 5166 degrees of freedom
Multiple R-squared:  0.0006334, Adjusted R-squared:  0.0002465
F-statistic: 1.637 on 2 and 5166 DF,  p-value: 0.1946
```

Figura 5.26: Test di Breush-Pagan e White

5.7 Modello di interazione pesato

Si pesa il modello secondo la tecnica WLS (Weighted Least Squares), come già fatto in precedenza.

```
Call:
lm(formula = CO2.Emissions.g.km. ~ Engine.Size.L. + Cylinders +
    Fuel.Consumption.City..L.100.km. + Fuel.Consumption.Hwy..L.100.km. +
    Fuel.Consumption.Comb..L.100.km. + Fuel_Type_X + Fuel_Type_Z +
    Fuel.Consumption.Hwy..L.100.km.:Fuel_Type_X + Fuel.Consumption.Hwy..L.100.km.:Fuel_Type_Z +
    Fuel.Consumption.City..L.100.km.:Fuel_Type_Z + Fuel.Consumption.City..L.100.km.:Fuel_Type_X +
    Fuel.Consumption.City..L.100.km.:Fuel.Consumption.Comb..L.100.km. +
    Cylinders:Fuel.Consumption.Hwy..L.100.km. + Engine.Size.L.:Fuel_Type_Z +
    Engine.Size.L.:Fuel_Type_X + Engine.Size.L.:Fuel.Consumption.Comb..L.100.km. +
    Engine.Size.L.:Cylinders + Cylinders:Fuel.Consumption.City..L.100.km.,
    data = train, weights = weights)

Weighted Residuals:
    Min      1Q  Median      3Q     Max
-3.9811 -1.0023  0.9402  0.9891  1.7712

Coefficients:
                                                    Estimate Std. Error t value Pr(>|t|)
(Intercept)                                        1.485e+02  3.604e-01  411.93   <2e-16 ***
Engine.Size.L.                                     3.115e+01  1.141e-01  273.08   <2e-16 ***
Cylinders                                          5.190e+00  4.346e-02  119.41   <2e-16 ***
Fuel.Consumption.City..L.100.km.                  -2.020e+01  9.053e-02 -223.17   <2e-16 ***
Fuel.Consumption.Hwy..L.100.km.                    9.368e+00  1.143e-01   81.93   <2e-16 ***
Fuel.Consumption.Comb..L.100.km.                   1.223e+01  8.102e-02  150.98   <2e-16 ***
Fuel_Type_X                                       -1.485e+02  3.085e-01 -481.23   <2e-16 ***
Fuel_Type_Z                                       -1.480e+02  3.086e-01 -479.39   <2e-16 ***
Fuel.Consumption.Hwy..L.100.km.:Fuel_Type_X       -4.380e+00  1.029e-01  -42.56   <2e-16 ***
Fuel.Consumption.Hwy..L.100.km.:Fuel_Type_Z       -4.377e+00  1.028e-01  -42.55   <2e-16 ***
Fuel.Consumption.City..L.100.km.:Fuel_Type_Z       2.306e+01  7.242e-02  318.45   <2e-16 ***
Fuel.Consumption.City..L.100.km.:Fuel_Type_X       2.316e+01  7.196e-02  321.85   <2e-16 ***
Fuel.Consumption.City..L.100.km.:Fuel.Consumption.Comb..L.100.km.  4.538e-01  2.145e-03  211.60   <2e-16 ***
Cylinders:Fuel.Consumption.Hwy..L.100.km.         -2.509e-01  4.888e-03  -51.34   <2e-16 ***
Engine.Size.L.:Fuel_Type_Z                        -2.862e+01  9.980e-02 -286.73   <2e-16 ***
Engine.Size.L.:Fuel_Type_X                        -2.869e+01  1.002e-01 -286.19   <2e-16 ***
Engine.Size.L.:Fuel.Consumption.Comb..L.100.km.   -9.811e-01  6.659e-03 -147.34   <2e-16 ***
Engine.Size.L.:Cylinders                           1.317e+00  6.192e-03  212.67   <2e-16 ***
Cylinders:Fuel.Consumption.City..L.100.km.        -5.243e-01  4.311e-03 -121.62   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9932 on 5150 degrees of freedom
Multiple R-squared:      1,     Adjusted R-squared:      1
F-statistic: 4.182e+07 on 18 and 5150 DF,  p-value: < 2.2e-16
```

Figura 5.27: Modello di interazione pesato

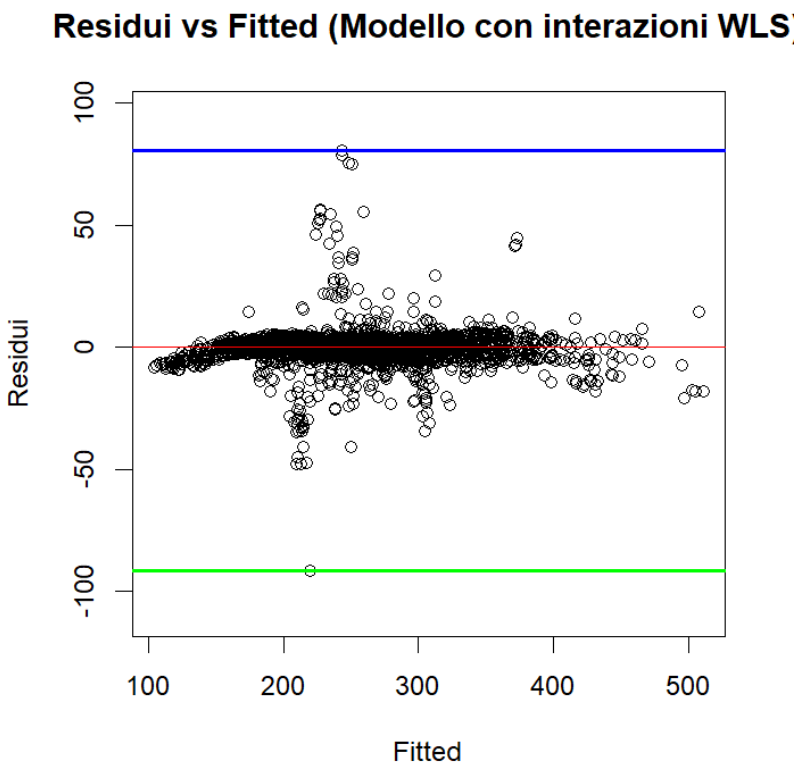


Figura 5.28: Modello pesato con interazioni

Adesso, entrambi i test supportano l'ipotesi iniziale (omoschedasticità), confermando l'assenza di eteroschedasticità nel modello.

```
> # Test di breusch-pagan
> bptest(interaction_model_wls)

        studentized Breusch-Pagan test

data:  interaction_model_wls
BP = 4.4776, df = 18, p-value = 0.9995

>
> # Test di white
> fit_mod_inter<- y_fit^2
> modwhite<- lm(residui^2~y_fit+fit_mod_inter)
> summary(modwhite)

Call:
lm(formula = residui^2 ~ y_fit + fit_mod_inter)

Residuals:
   Min     1Q Median     3Q    Max
 -56.5  -48.3  -41.3  -34.0 8361.5

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)   -4.471e+01  5.992e+01  -0.746    0.456
y_fit          6.286e-01  4.534e-01   1.386    0.166
fit_mod_inter -9.758e-04  8.345e-04  -1.169    0.242

Residual standard error: 307.3 on 5166 degrees of freedom
Multiple R-squared:  0.0006655, Adjusted R-squared:  0.0002786
F-statistic:  1.72 on 2 and 5166 DF,  p-value: 0.1791
```

Figura 5.29: Test di Breush-Pagan e White

Capitolo 6

Regolarizzazione

Si è deciso di adottare tecniche di regolarizzazione, come la Ridge Regression, il Lasso e l'Elastic Net, per affrontare i problemi legati alla multicollinearità.

```
> # Divisione del training set
> X_train <- as.matrix(train[, -which(names(train) == "CO2.Emissions.g.km.")])
> y_train <- train$CO2.Emissions.g.km.
>
> # Divisione del test set
> X_test <- as.matrix(test[, -which(names(test) == "CO2.Emissions.g.km.")])
> y_test <- test$CO2.Emissions.g.km.
```

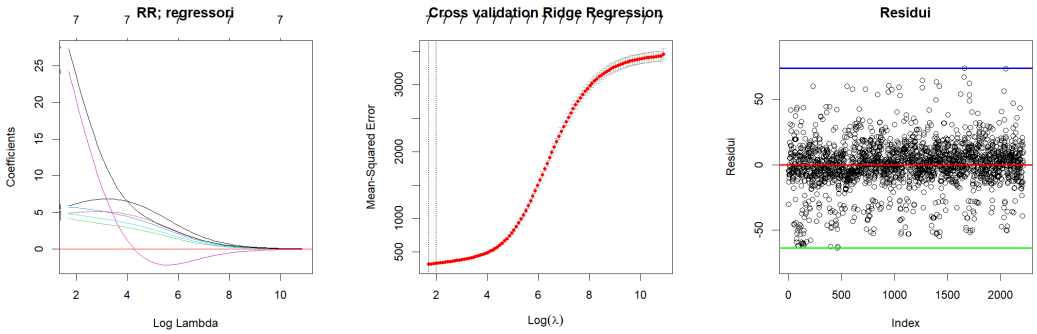
Figura 6.1: Divisione del training e del test set

6.1 Ridge Regression

La **Ridge Regression** è una tecnica di regressione che aggiunge una penalizzazione L2 (somma dei quadrati dei coefficienti) alla funzione di costo, riducendo i coefficienti del modello per gestire la multicollinearità e prevenire l'overfitting.

```
> ################## RIDGE REGRESSION ######################
> # Intero dataset
> ridge_all <- glmnet(X_train, y_train, alpha = 0, lambda = NULL)
> coef(ridge_all)[,1]
                    (Intercept)                   Engine.Size.L.                        Cylinders
                   2.505643e+02                    3.718909e-35                     2.710498e-35
Fuel.Consumption.City..L.100.km.  Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.
                   1.553766e-35                    2.355933e-35                     1.878262e-35
                     Fuel_Type_X                     Fuel_Type_Z
                   -3.117246e-35                    2.729979e-35
> plot(ridge_all,main='RR; regressori', xvar='lambda', label = TRUE)
> abline(h = 0, col = "red")
>
> # Esecuzione della 10-fold cross-validation per Ridge regression (alpha = 0 per L2)
> ridge_cv <- cv.glmnet(X_train, y_train, nfolds = 10, alpha = 0)
>
> plot(ridge_cv, main = "Cross validation Ridge Regression")
> cat("Lambda ottimale:", ridge_cv$lambda.min, "\n")
Lambda ottimale: 5.409623
>
> ridge_min <- glmnet(X_train, y_train, alpha = 0, lambda = ridge_cv$lambda.min)
>
> coef(ridge_min)[,1]
                    (Intercept)                   Engine.Size.L.                        Cylinders
                      23.914414                        5.901168                         4.881575
Fuel.Consumption.City..L.100.km.  Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.
                       4.117924                        5.691883                         4.885605
                     Fuel_Type_X                     Fuel_Type_Z
                      24.213245                       27.298426
>
> # Predizione
> ridge_pred <- predict(ridge_min, X_test)
> # Calcolo dell'errore (ad esempio, MSE)
> mse <- mean((ridge_pred - y_test)^2)
> cat("MSE per Ridge:", mse, "\n")
MSE per Ridge: 296.4778
```

Figura 6.2: Ridge Regression



Mediante la cross-validation, si sceglie di considerare il lambda che minimizza il MSE (Mean Squared Error).

6.2 Lasso

Il **Lasso** (*Least Absolute Shrinkage and Selection Operator*) è una tecnica di regressione che applica una penalizzazione L1 (somma dei valori assoluti dei coefficienti) alla funzione di costo. Questo metodo riduce alcuni coefficienti a zero, consentendo la selezione automatica delle variabili più rilevanti e migliorando al contempo la capacità di generalizzazione del modello.

```
> # Intero dataset
> lasso_all <- glmnet(X_train, y_train, alpha = 1, lambda = NULL)
> coef(lasso_all)[,1]
                    (Intercept)                    Engine.Size.L.                         Cylinders
                        250.5643                            0.0000                            0.0000
Fuel.Consumption.City..L.100.km.  Fuel.Consumption.Hwy..L.100.km.  Fuel.Consumption.Comb..L.100.km.
                            0.0000                            0.0000                            0.0000
                     Fuel_Type_X                       Fuel_Type_Z
                            0.0000                            0.0000
> plot(lasso_all,main='LASSO; regressori', xvar='lambda', label = TRUE)
> abline(h = 0, col = "red", lwd = 2) # Linea a y = 0
>
> # Esecuzione della 10-fold cross-validation per Lasso (alpha = 1 per L1)
> lasso_cv <- cv.glmnet(X_train, y_train, nfolds = 10, alpha = 1)
>
> plot(lasso_cv, main = "Cross validation Lasso")
> cat("Lambda ottimale:", lasso_cv$lambda.min, "\n")
Lambda ottimale: 0.07319478
>
> lasso_min <- glmnet(X_train, y_train, alpha = 1, lambda = lasso_cv$lambda.min)
>
> coef(lasso_min)[,1]
                    (Intercept)                    Engine.Size.L.                         Cylinders
                    -11.5424273                         3.3841966                         4.1444498
Fuel.Consumption.City..L.100.km.  Fuel.Consumption.Hwy..L.100.km.  Fuel.Consumption.Comb..L.100.km.
                     8.8386585                         7.6466254                         0.2329277
                     Fuel_Type_X                       Fuel_Type_Z
                     48.1156814                        50.0837664
>
> # Predizione
> lasso_pred <- predict(lasso_min, X_test)
> # Calcolo dell'errore (ad esempio, MSE)
> mse <- mean((lasso_pred - y_test)^2)
> cat("MSE per Lasso:", mse, "\n")
MSE per Lasso: 266.1488
>
```

Figura 6.3: Lasso

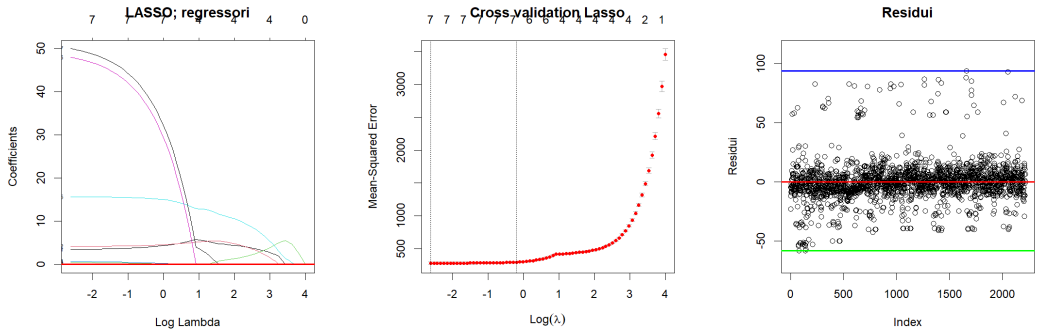


Figura 6.4: Lasso

Mediante la cross-validation, si sceglie di considerare il lambda che minimizza il MSE (Mean Squared Error).

6.3 Elastic Net

L'**Elastic Net** è una tecnica di regressione che combina le penalizzazioni L1 (Lasso) e L2 (Ridge), ed è utile per selezionare variabili e migliorare la generalizzazione del modello. È particolarmente efficace in presenza di variabili altamente correlate.

6.3.1 Elastic Net $\alpha = 0.25$

```
> # Intero dataset
> EN1_all <- glmnet(X_train, y_train, alpha = 0.25, lambda = NULL)
> coef(EN1_all)[,1]
                      (Intercept)                  Engine.Size.L.                       Cylinders
                        250.5643                          0.0000                          0.0000
Fuel.Consumption.City..L.100.km.  Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.
                          0.0000                          0.0000                          0.0000
                     Fuel_Type_X                     Fuel_Type_Z
                          0.0000                          0.0000
> plot(EN1_all,main='Elastic Net; regressori', xvar='lambda', label = TRUE)
> abline(h = 0, col = "red", lwd = 2) # Linea a y = 0
>
> # Esecuzione della 10-fold cross-validation per Elastic Net (alpha = 0.25 per L1)
> EN1_cv <- cv.glmnet(X_train, y_train, nfolds = 10, alpha = 0.25)
>
> plot(EN1_cv, main = "Cross validation Elastic Net alpha = 0.25")
> cat("Lambda ottimale:", EN1_cv$lambda.min, "\n")
Lambda ottimale: 0.1390938
>
> EN1_min <- glmnet(X_train, y_train, alpha = 0.25, lambda = EN1_cv$lambda.min)
>
> coef(EN1_min)[,1]
                      (Intercept)                  Engine.Size.L.                       Cylinders
                       -11.441119                        3.450362                        4.154052
Fuel.Consumption.City..L.100.km.  Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.
                         6.148540                        5.557092                        5.008882
                     Fuel_Type_X                     Fuel_Type_Z
                        47.986889                       49.973473
>
> # Predizione
> EN1_pred <- predict(EN1_min, X_test)
> # Calcolo dell'errore (ad esempio, MSE)
> mse <- mean((EN1_pred - y_test)^2)
> cat("MSE per Elastic Net alpha=0.25:", mse, "\n")
MSE per Elastic Net alpha=0.25: 266.0405
```

Figura 6.5: Elastic Net $\alpha = 0.25$

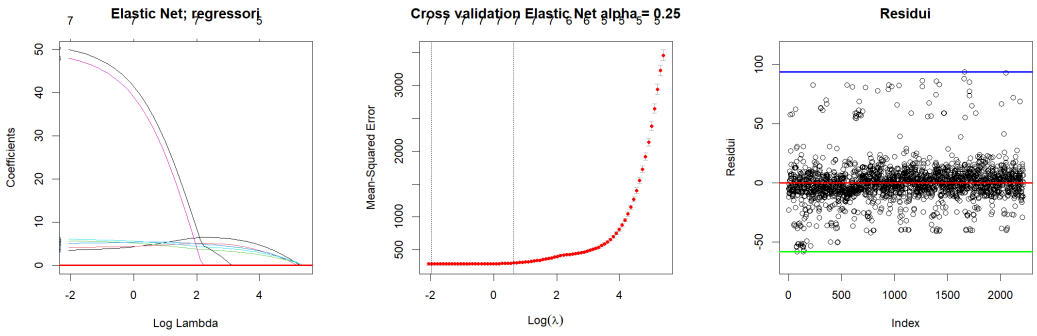


Figura 6.6: Elastic Net 0.5

6.3.2 Elastic Net $\alpha = 0.5$

```
> # Intero dataset
> EN2_all <- glmnet(X_train, y_train, alpha = 0.5, lambda = NULL)
> coef(EN2_all)[,1]
                    (Intercept)                    Engine.Size.L.                         Cylinders
                     250.5643                            0.0000                            0.0000
Fuel.Consumption.City..L.100.km.  Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.
                            0.0000                            0.0000                            0.0000
                    Fuel_Type_X                       Fuel_Type_Z
                            0.0000                            0.0000
> plot(EN2_all,main='Elastic Net; regressori', xvar='lambda', label = TRUE)
> abline(h = 0, col = "red", lwd = 2) # Linea a y = 0
>
> # Esecuzione della 10-fold cross-validation per Elastic Net (alpha = 0.5 per L1)
> EN2_cv <- cv.glmnet(X_train, y_train, nfolds = 10, alpha = 0.5)
>
> plot(EN2_cv, main = "Cross validation Elastic Net alpha = 0.5")
> cat("Lambda ottimale:", EN2_cv$lambda.min, "\n")
Lambda ottimale: 0.1107383
>
> EN2_min <- glmnet(X_train, y_train, alpha = 0.5, lambda = EN2_cv$lambda.min)
>
> coef(EN2_min)[,1]
                    (Intercept)                    Engine.Size.L.                         Cylinders
                     -11.413866                         3.418516                          4.147849
Fuel.Consumption.City..L.100.km.  Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.
                            6.550970                          5.817086                          4.343055
                    Fuel_Type_X                       Fuel_Type_Z
                           48.002973                         49.983021
>
> # Predizione
> EN2_pred <- predict(EN2_min, X_test)
> # Calcolo dell'errore (ad esempio, MSE)
> mse <- mean((EN2_pred - y_test)^2)
> cat("MSE per Elastic Net alpha=0.5:", mse, "\n")
MSE per Elastic Net alpha=0.5: 266.0266
`
```

Figura 6.7: Elastic Net $\alpha = 0.5$

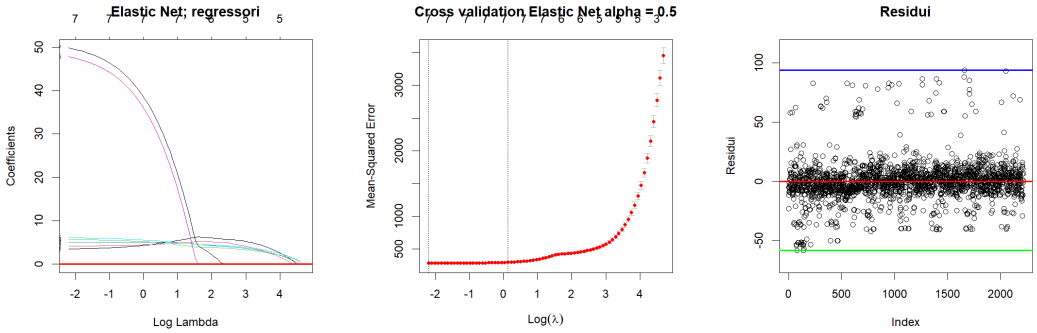


Figura 6.8: Elastic Net 0.75

6.3.3 Elastic Net $\alpha = 0.75$

```
> # Intero dataset
> EN3_all <- glmnet(X_train, y_train, alpha = 0.75, lambda = NULL)
> coef(EN3_all)[,1]
                    (Intercept)                    Engine.Size.L.                         Cylinders
                     250.5643                            0.0000                            0.0000
Fuel.Consumption.City..L.100.km.  Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.
                            0.0000                            0.0000                            0.0000
                    Fuel_Type_X                       Fuel_Type_Z
                            0.0000                            0.0000
> plot(EN3_all,main='Elastic Net; regressori', xvar='lambda', label = TRUE)
> abline(h = 0, col = "red", lwd = 2) # Linea a y = 0
>
> # Esecuuzione della 10-fold cross-validation per Elastic Net (alpha = 0.75 per L1)
> EN3_cv <- cv.glmnet(X_train, y_train, nfolds = 10, alpha = 0.75)
>
> plot(EN3_cv, main = "Cross validation Elastic Net alpha = 0.75")
> cat("Lambda ottimale:", EN3_cv$lambda.min, "\n")
Lambda ottimale: 0.08892315
>
> EN3_min <- glmnet(X_train, y_train, alpha = 0.75, lambda = EN3_cv$lambda.min)
>
> coef(EN3_min)[,1]
                    (Intercept)                    Engine.Size.L.                         Cylinders
                     -11.471660                         3.394030                          4.142318
Fuel.Consumption.City..L.100.km.  Fuel.Consumption.Hwy..L.100.km. Fuel.Consumption.Comb..L.100.km.
                            7.515508                          6.557212                          2.640074
                    Fuel_Type_X                       Fuel_Type_Z
                           48.065507                         50.036617
>
> # Predizione
> EN3_pred <- predict(EN3_min, X_test)
> # Calcolo dell'errore (ad esempio, MSE)
> mse <- mean((EN3_pred - y_test)^2)
> cat("MSE per Elastic Net alpha=0.75:", mse, "\n")
MSE per Elastic Net alpha=0.75: 266.0598
```

Figura 6.9: Elastic Net $\alpha = 0.75$

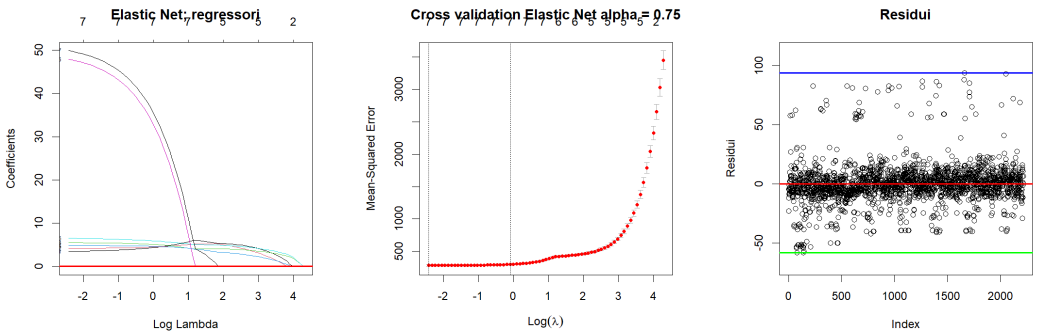


Figura 6.10: Elastic Net 0.75

6.4 Confronto tra modello con interazioni WLS, Elastic Net(0.5) e log-lin

Si sceglie di confrontare, in definitiva, i tre modelli considerati più promettenti:

- Log-Lin: è il modello ottenuto da una trasformazione del modello lineare, con assenza di multicollinearità ma con presenza di eteroschedasticità;
- Modello con interazione WLS: è il modello pesato ottenuto dalla selezione automatica dei regressori lineari e dalle loro interazioni, con presenza di multicollinearità ma con assenza di eteroschedasticità;
- Modello Elastic Net $\alpha = 0.5$: è il modello "migliore" (utilizzando il MSE come metrica) tra quelli generati con le tecniche di regolarizzazione.

Si confrontano le metriche MSE e i residui dei tre modelli.

```
> ##### Confronto tra modello con interazioni WLS, Elastic Net(0.5) e log-lin #####
>
> # Predizione per il modello log-lin
> pred_log <- exp(predict(model_log, newdata = test))
>
> # Calcolo dell'errore quadratico medio (MSE) per il modello log-lin
> mse_log <- mean((pred_log - test$CO2.Emissions.g.km.)^2)
> cat("MSE per Log-Lin Pesato:", mse_log, "\n")
MSE per Log-Lin Pesato: 368.72
>
> # Calcolo dell'errore assoluto medio (MAE) per il modello log-lin
> mae_log <- mean(abs(pred_log - test$CO2.Emissions.g.km.))
> cat("MAE per Log-Lin Pesato:", mae_log, "\n")
MAE per Log-Lin Pesato: 11.89976
>
>
> # Predizione per il modello con interazioni WLS
> pred_interaction_wls <- predict(interaction_model_wls, newdata = test)
>
> # Calcolo dell'errore quadratico medio (MSE) per il modello con interazioni pesato
> mse_interaction_wls <- mean((pred_interaction_wls - test$CO2.Emissions.g.km.)^2)
> cat("MSE per Modello con Interazioni:", mse_interaction_wls, "\n")
MSE per Modello con Interazioni: 38.94811
>
> # Calcolo dell'errore assoluto medio (MAE) per il modello con interazioni pesato
> mae_interaction_wls <- mean(abs(pred_interaction_wls - test$CO2.Emissions.g.km.))
> cat("MAE per Modello con Interazioni:", mae_interaction_wls, "\n")
MAE per Modello con Interazioni: 3.403574
>
>
> # Predizione per il modello Elastic Net
> EN_pred_test <- predict(EN2_min, newx = X_test)
>
> # Calcolo dell'errore quadratico medio (MSE) per il modello Elastic Net
> mse_en <- mean((EN_pred_test - y_test)^2)
> cat("MSE per Elastic Net:", mse_en, "\n")
MSE per Elastic Net: 266.0266
>
> # Calcolo dell'errore assoluto medio (MAE) per il modello Elastic Net
> mae_en <- mean(abs(EN_pred_test - y_test))
> cat("MAE per Elastic Net:", mae_en, "\n")
MAE per Elastic Net: 9.966335
```

Figura 6.11: Confronto tra modelli

6.5 Confronto dei residui

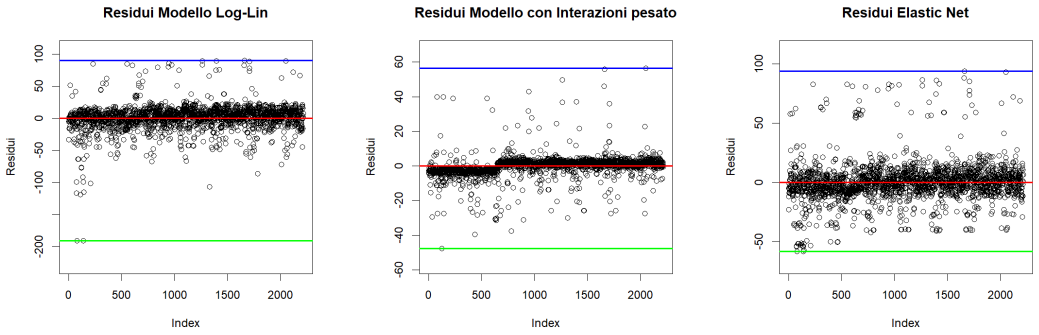


Figura 6.12: Confronto dei residui

- Il **modello Log-Lin** presenta residui con maggiore dispersione e alcuni valori anomali evidenti, indicando una minore aderenza ai dati.
- Il **modello con interazioni pesato** evidenzia residui più compatti e distribuiti attorno allo zero, suggerendo una migliore capacità predittiva rispetto al Log-Lin.

- Il **modello Elastic Net** mostra residui distribuiti in modo moderatamente omogeneo, con presenza di outlier meno pronunciata rispetto al primo modello ma non del tutto trascurabile.

Questa analisi indica che il modello con interazioni pesato offre prestazioni migliori in termini di distribuzione dei residui, seguito dal modello Elastic Net.

6.6 Confronto finale tra i modelli

Model	MSE	MAE
Log-Lin	368.72002	11.899760
Modello con Interazioni pesato	38.94811	3.403574
Elastic Net	266.02662	9.966335

Figura 6.13: Confronto finale modelli

La tabella di confronto tra i tre modelli — Log-Lin, Modello con Interazioni Pesate ed Elastic Net — ci offre una panoramica chiara sulle loro prestazioni, valutate attraverso due metriche chiave: MSE (Mean Squared Error) e MAE (Mean Absolute Error). Queste metriche ci aiutano a comprendere l'accuratezza predittiva di ciascun modello, con l'MSE che dà maggior peso agli errori grandi e il MAE che misura l'errore medio assoluto, risultando meno influenzato dagli outlier.

Analizzando i risultati, emergono alcune osservazioni interessanti. Il modello Log-Lin è quello con le prestazioni più deboli, registrando i valori più alti sia per MSE che per MAE. Questo indica che, in media, gli errori commessi da questo modello sono più grandi rispetto agli altri due, rendendolo il meno adatto per il contesto analizzato. Questo comportamento era prevedibile data la "pericolosità" dell'eteroschedasticità che si riflette nella predizione.

Al contrario, il modello con interazioni pesate si distingue nettamente per avere i valori più bassi di entrambe le metriche, dimostrando di essere il più accurato tra i tre. L'introduzione delle interazioni pesate sembra aver contribuito a migliorare significativamente la capacità del modello di catturare le relazioni sottostanti nei dati. Questo comportamento non ci sorprende: la multicollinearità è molto meno dannosa dell'eteroschedasticità nelle predizioni.

Infine, l'Elastic Net si posiziona a metà strada. Esso ha un MSE superiore rispetto al modello con interazioni pesate, ma inferiore rispetto al modello Log-Lin, suggerendo che riesce a ridurre meglio gli errori medi assoluti.

Capitolo 7

Conclusioni

Per concludere il modello finale ottenuto attraverso le varie tecniche utilizzate è il seguente:

$$
\begin{aligned}
\hat{y} = {} & 148.5\,(\text{Intercept}) + 31.15 \cdot \text{Engine.Size.L.} + 5.19 \cdot \text{Cylinders} \\
& - 20.20 \cdot \text{Fuel.Consumption.City..L.100.km.} \\
& + 9.37 \cdot \text{Fuel.Consumption.Hwy..L.100.km.} \\
& + 12.23 \cdot \text{Fuel.Consumption.Comb..L.100.km.} \\
& - 148.5 \cdot \text{Fuel_Type_X} - 148.0 \cdot \text{Fuel_Type_Z} \\
& - 4.38 \cdot (\text{Fuel.Consumption.Hwy..L.100.km.} \cdot \text{Fuel_Type_X}) \\
& - 4.38 \cdot (\text{Fuel.Consumption.Hwy..L.100.km.} \cdot \text{Fuel_Type_Z}) \\
& + 23.06 \cdot (\text{Fuel.Consumption.City..L.100.km.} \cdot \text{Fuel_Type_X}) \\
& + 23.16 \cdot (\text{Fuel.Consumption.City..L.100.km.} \cdot \text{Fuel_Type_Z}) \\
& + 0.4538 \cdot (\text{Fuel.Consumption.City..L.100.km.} \cdot \text{Fuel.Consumption.Comb..L.100.km.}) \\
& - 2.509 \cdot (\text{Cylinders} \cdot \text{Fuel.Consumption.Hwy..L.100.km.}) \\
& - 2.862 \cdot (\text{Engine.Size.L.} \cdot \text{Fuel_Type_Z}) \\
& - 2.869 \cdot (\text{Engine.Size.L.} \cdot \text{Fuel_Type_X}) \\
& - 9.811 \cdot (\text{Engine.Size.L.} \cdot \text{Fuel.Consumption.Comb..L.100.km.}) \\
& + 1.317 \cdot (\text{Engine.Size.L.} \cdot \text{Cylinders}) \\
& - 5.243 \cdot (\text{Cylinders} \cdot \text{Fuel.Consumption.City..L.100.km.})\,.
\end{aligned}
$$